

# Ikhtisar metode deteksi dan klasifikasi rambu lalu lintas

Yassmina Saadna<sup>1</sup> · Ali Behloul<sup>1</sup>

Diterima: 10 Februari 2017 / Direvisi: 20 Mei 2017 / Diterima: 26 Mei 2017 / Diterbitkan online: 6 Juni 2017 © Springer-Verlag London 2017

**Abstrak**Selama beberapa tahun terakhir, sistem pengenalan rambu lalu lintas yang berbeda telah diusulkan. Makalah ini memperkenalkan gambaran umum beberapa metode terkini dan efisien dalam deteksi dan klasifikasi rambu lalu lintas. Memang benar, tujuan utama metode pendeteksian adalah melokalisasi wilayah yang memiliki rambu lalu lintas, dan kami membagi metode pendeteksian menjadi tiga kategori utama: berbasis warna (diklasifikasikan menurut ruang warna), berbasis bentuk, dan metode berbasis pembelajaran (termasuk pembelajaran mendalam). Selain itu, kami juga membagi metode klasifikasi menjadi dua kategori: metode pembelajaran berdasarkan fitur kerajinan tangan (HOG, LBP, SIFT, SURF, BRISK) dan metode deep learning. Untuk memudahkan referensi, berbagai metode deteksi dan klasifikasi dirangkum dalam tabel bersama dengan kumpulan data yang berbeda. Selanjutnya diberikan arahan dan rekomendasi penelitian kedepannya guna mendongkrak kinerja TSR.

**Kata kunci**Deteksi rambu lalu lintas·Klasifikasi rambu lalu lintas·Pengolahan citra·Deteksi objek·Keamanan kendaraan

## 1. Perkenalan

PBB memperkirakan antara tahun 2010 dan 2020 jumlah kematian di jalan raya akan meningkat hingga 50%, yaitu sekitar 1,9 juta orang. Untuk membalikkan tren ini, pada tahun 2011 PBB menetapkan “Dekade Aksi untuk Keselamatan Jalan” yang pertama.

Sistem Bantuan Pengemudi dapat membantu mengurangi jumlah kecelakaan dengan mengotomatiskan tugas-tugas seperti sistem peringatan keberangkatan jalur, pengenalan rambu lalu lintas.

Pengenalan rambu lalu lintas semakin mendapat perhatian dalam beberapa tahun terakhir; bahkan dianggap sebagai fitur yang sangat penting pada kendaraan cerdas. Rambu lalu lintas membawa informasi penting yang mungkin diabaikan oleh pengemudi karena kelelahan mengemudi atau alasan mencari alamat. Para pengemudi juga cenderung kurang memperhatikan rambu-rambu lalu lintas saat berkendara dalam cuaca buruk. Oleh karena itu, inisiatif peningkatan, seperti peningkatan keselamatan berkendara serta peningkatan deteksi otomatis dan sistem pengenalan rambu jalan, menjadi sangat diperlukan untuk membantu mengurangi angka kematian di jalan raya. Peningkatan ini, betapapun bermanfaatnya, menghadapi beberapa tantangan non-teknis eksternal seperti variasi pencahayaan, perubahan skala dan kondisi cuaca, oklusi dan rotasi, yang pada akhirnya dapat menurunkan kinerja sistem pengenalan rambu lalu lintas.

Permasalahan utama dalam sistem pengenalan rambu lalu lintas bukanlah bagaimana mendeteksi atau mengenali, dengan recall yang tinggi, suatu rambu lalu lintas pada gambar diam. Ini lebih tentang bagaimana mendapatkan presisi tinggi dalam video big data. Untuk mengilustrasikan masalah alarm palsu, sistem pengenalan rambu lalu lintas yang dipasang di ponsel pintar, dengan 30 frame pengambilan gambar per detik, (108.000 frame dalam video berdurasi 1 jam), dipertimbangkan. Jika kita asumsikan bahwa dalam setiap 4 menit kita mendeteksi sebuah tanda dan bahwa—dengan mengacu pada kecepatan sebuah mobil—setiap tanda memerlukan waktu 2 detik, ini berarti bahwa dalam waktu 1 jam kita akan menemukan total 15 tanda dan setiap tanda akan ditampilkan. dalam 60 frame (900 frame berisi tanda sedangkan 107.100 tidak). Misalkan juga sistem memiliki tingkat akurasi positif palsu 1%, ini berarti ada 17 alarm palsu yang terdeteksi dalam 1 menit (1071 dalam 1 jam) dan 1 positif benar dan 68 alarm palsu dalam 4 menit sebagai konsekuensinya. Hal ini pada akhirnya dapat menyebabkan sebagian besar pengguna menonaktifkan aplikasi mereka.

BYassmina Saadna  
yassmina.saadna@gmail.com

Ali Behloul  
a.behloul@univ-batna2.dz

<sup>1</sup> Laboratorium LaSTIC, Departemen Ilmu Komputer, Universitas Batna 2, Batna, Aljazair



Gambar 1 Jenis rambu lalu lintas: A, tanda wajib, B, tanda sementara, C, memperingatkan, D, tanda larangan, E, tanda reservasi

Sistem pengenalan rambu lalu lintas terdiri dari tiga tahap utama: lokalisasi, deteksi, dan klasifikasi. Jika ada alarm palsu pada tahap deteksi, kinerjanya akan lebih rendah pada tahap klasifikasi; hal ini disebabkan oleh fakta bahwa pengklasifikasi biasanya tidak dilatih tentang alarm palsu.

Rambu-rambu jalan mempunyai banyak ciri pembeda yang menjadi dasar pengklasifikasiannya. Menurut bentuk dan warnanya, ada lima golongan utama: rambu peringatan (segitiga merah), rambu larangan (lingkaran merah), rambu larangan (persegi panjang biru), rambu wajib (lingkaran biru), dan rambu sementara (segitiga kuning). Contoh rambu lalu lintas untuk masing-masing kategori yang disebutkan di atas ditunjukkan pada Gambar.1.

Tujuan dari makalah ini adalah untuk menyajikan gambaran umum tentang beberapa metode deteksi dan klasifikasi rambu lalu lintas yang terkini dan efisien; beberapa penulis menyukai [1–4,15,36] juga lebih disukai untuk melakukan studi pada domain ini.

Serangga.2, metode deteksi rambu lalu lintas disajikan; mereka telah dibagi menjadi tiga kategori: metode berbasis warna, berbasis bentuk, dan berbasis pembelajaran, termasuk metode pembelajaran mendalam. Serangga.3, metode klasifikasi rambu lalu lintas ditekankan, pertama kami mengutip metode pembelajaran berdasarkan fitur buatan tangan, dan kemudian, kami menyebutkan metode pembelajaran mendalam. Selain itu, berbagai kumpulan data deteksi dan klasifikasi rambu lalu lintas yang tersedia untuk umum juga disajikan untuk membantu mencapai tujuan makalah ini. Bagian4 menjelaskan arah penelitian masa depan yang dapat digabungkan dengan peneliti dalam pekerjaan mereka di masa depan. Akhirnya, sebuah kesimpulan diharapkan.

## 2 Metode deteksi

Seperti disebutkan di atas, kita dapat mengklasifikasikan metode deteksi atau lokalisasi menjadi tiga kelas dasar: metode berbasis warna, berbasis bentuk, dan berbasis pembelajaran. Berdasarkan sifat masalah dan persyaratan sistem, kami dapat memutuskan metode terbaik untuk diterapkan; misalnya, metode berdasarkan informasi warna dapat digunakan dengan kumpulan data resolusi tinggi, namun tidak dengan gambar skala abu-abu.

### 2.1 Metode berbasis warna

Segmentasi berbasis warna dominan diterapkan untuk mendeteksi wilayah yang diminati. Ada ciri khas warna rambu lalu lintas: merah, biru, dan kuning. Namun karakteristik ini menunjukkan kepekaan terhadap berbagai faktor, misalnya

seiring bertambahnya usia tanda dan variasi cahaya, yang membuat segmentasi menjadi proses yang sulit. Untuk mengatasi masalah ini, penulis sedang mengerjakan ruang warna yang berbeda, di antaranya kami sebutkan sebagai berikut:

#### 2.1.1 Ruang RGB

De La Escalera dkk. [5] mengadopsi ruang RGB dengan alasan rumus HSI bersifat nonlinier. Penulis menggunakan hubungan antar komponen seperti yang disajikan dalam ungkapan berikut:

$$g(x, kamu) = \begin{cases} R \leq Fr(x, kamu) \leq RB \\ PTAS \leq \frac{Fg(x,y)}{Fr(x,y)} \leq PTB \\ TBCA \leq \frac{Fg(x,y)}{Fb(x,y)} \leq TBCB \end{cases} \quad (1)$$

$g(x, kamu) = k_2$  dalam kasus lain

$Fr(x, y)$ ,  $Fg(x, kamu)$ , Dan  $Fb(x, kamu)$  masing-masing adalah fungsi yang memberikan tingkat merah, hijau, dan biru pada setiap titik pada gambar.

Ambang batas digunakan oleh beberapa penulis sebagai [6–8]. Namun pendekatan mereka sangat terkait dengan ambang batas yang dipilih, sehingga membuat perbandingan kinerja mereka menjadi tugas yang sulit.

Ruta dkk. [7] menerapkan pemfilteran untuk setiap piksel:  $X = [Xr, Xg, Xb]$  Dan  $S = Xr + Xg + Xb$

$$Fr(X) = \max(0, \min(Xr - Xg, Xr - Xb) / S) \quad (2)$$

$$\max(0, \min(Xb - Xr, Xb - Xg) / S) \quad (3)$$

$$0, \min(Xr - Xb, Xg - Xb) / S) \quad (4)$$

Dalam pendekatan ini, mereka menghasilkan tiga peta berwarna merah, biru, dan kuning untuk setiap gambar RGB. Warna dominan memiliki intensitas yang tinggi, sedangkan sinyal yang memburuk memiliki intensitas yang rendah. Raja dkk. [9] lebih memilih ruang R'G'B'. Pertama, mereka menormalkan tiga saluran RGB berdasarkan intensitas I:

$$SAYA = \frac{R+G+B}{3} \quad (5)$$

$$R = \frac{R}{SAYA}, G = \frac{G}{SAYA}, B = \frac{B}{SAYA} \quad (6)$$

Kemudian, mereka membuat empat gambar baru sesuai dengan persamaan yang diajukan oleh [10]:

$$R = R - \frac{(G+B)}{2} \quad (7)$$

$$G = G - \frac{(R+B)}{2} \quad (8)$$

$$B = B - \frac{(R+G)}{2} \quad (9)$$

$$Y = \frac{R+G}{2} - \frac{|R-G|}{2} - B \quad (10)$$

Warna dominan memiliki intensitas tinggi yang memudahkan ekstraksi panel. Thresholding digunakan untuk melakukan binerisasi empat gambar (R, G, B, Y); operasi morfologi kemudian diterapkan untuk menghilangkan piksel yang tidak diinginkan. Perlu digarisbawahi bahwa pendekatan ini mampu mendeteksi hingga 93,63% panel.

Pendekatan King et al. diadopsi di [11]. Filter diusulkan untuk menghilangkan piksel yang tidak diinginkan dengan maksud untuk mengurangi waktu eksekusi.

### 2.1.2 Ruang HSV

Yakimov [12] menganggap tidak mungkin mendeteksi rambu lalu lintas pada gambar nyata dengan menerapkan ambang batas sederhana secara langsung di ruang RGB karena variasi pencahayaan; Hal inilah yang mendorong mereka untuk memilih ruang HSV. Mereka menggunakan metode eksperimental untuk menentukan nilai ambang batas optimal untuk warna merah seperti yang disajikan dalam ekspresi berikut:

$$(0.0H < 23) \vee (350 < H < 360) \wedge (0.85 < S \leq 1) \wedge (0.85 < V \leq 1)$$

Setelah segmentasi, mereka menggunakan algoritma yang dimodifikasi yang disajikan di [13] untuk menolak gambar tersegmentasi. Keuntungan dari algoritma denoising adalah hanya noise yang akan dihilangkan dan wilayah yang diinginkan tetap tidak terfilter.

Wang dkk. [14] juga memilih ruang HSV, dan mereka menemukan bahwa metode ambang batas klasik memberikan hasil yang baik dalam berbagai kondisi pencahayaan kecuali dalam kasus corak warna atau kondisi pencahayaan buruk. Mereka mengusulkan metode ambang batas baru dengan menggunakan informasi warna piksel tetangga. Pertama, derajat merah setiap titik  $c$  dihitung untuk mendapatkan bayangan baru  $Fr(C)$  dengan yang berikut ini persamaan:

$$Fr(C) = \begin{cases} S(c) \frac{\cos(H(c)-300)}{\cos(60)} & \text{jika } H(C) \in [300^\circ, 360^\circ] \\ S(c) \frac{\cos(60-H(c))}{\cos(60)} & \text{jika } H(C) \in [0^\circ, 60^\circ] \\ 0 & \text{yang lain} \end{cases} \quad (12)$$

Kedua, derajat merah yang dinormalisasi  $Ftidak(X)$  dihitung sebagai berikut:

$$Ftidak(X) = \frac{(f(x) - \mu_R(wX))}{(\sigma_R(wX))} \quad (13)$$

$\mu_R(wX)$  dan  $\sigma_R(wX)$  adalah mean dan varians derajat merah piksel di jendela  $wX$  berpusat pada  $X$ .

Ketiga, intensitas yang dinormalisasi  $Ftidak$  dihitung dengan persamaan berikut:

$$Ftidak(X) = \frac{(FsayA(X) - \mu_{sayA}(wX))}{(\sigma_{sayA}(wX))} \quad (14)$$

$FsayA(X)$  adalah intensitas piksel  $X$ ;  $\mu_{sayA}(wX)$  dan  $\sigma_{sayA}(wX)$  adalah mean dan varians intensitas piksel di jendela  $wX$ . Terakhir, bitmap merah  $B$  diberikan sebagai berikut:

$$B(x) = \begin{cases} 1 & \text{jika } Ftidak(x) > \max(THR1, Ftidak + THR2) \\ 0 & \text{yang lain} \end{cases} \quad (15)$$

Basconand dkk. [16] menggabungkan ambang batas pada komponen H dan S dengan dekomposisi akromatik. Metode ini, betapapun sederhana dan cepatnya, tidak kuat dalam memberi sinyal kerusakan dan perubahan pencahayaan. Fleyeh dkk. [17] menggunakan ambang batas pada komponen H, S, dan V; metode ini tahan terhadap perubahan pencahayaan, namun memakan waktu komputasi yang mahal. Vitale dkk. [18] di sisi lain menggunakan agregasi dinamis (11) teknik piksel untuk melakukan segmentasi citra.

### 2.1.3 Ruang HSI

Beberapa penulis memilih menggunakan ruang HSI karena komponen ronanya tidak berubah terhadap perubahan pencahayaan.

Escalera dkk. [19] telah memilih ruang HSI untuk mendeteksi tanda-tanda tersebut. hanya komponen H dan S yang digunakan untuk mengkompensasi masalah variasi kecerahan. Penulis membuat dua tabel pencarian (LUT): satu untuk tangan dan yang lainnya untuk komponen S. Idennya adalah bahwa masing-masing LUT menggantikan yang lain, yaitu jika suatu komponen memiliki nilai yang salah, maka komponen lainnya dapat memberikan kompensasi. Setelah LUT diterapkan, gambar yang dihasilkan dikalikan dan dibandingkan dengan logika konvensional AND.

Fang dkk. [20] berasumsi bahwa setiap warna tertentu dari suatu tanda dapat diwakili oleh nilai rona yang terdistribusi dengan varian  $\sigma$  Gaussian. Himpunan semua nilai rona ini dinotasikan sebagai  $H_1, H_2, \dots, H_Q$ ; lalu, aztingkat kemiripan antara warna piksel  $h$  dan rona tanda warna  $H_k$  dihitung sebagai berikut:

$$Z = \max_{k=1, \dots, Q} \left( \frac{1}{2\pi\sigma} \exp\left(-\frac{(h-H_k)^2}{2\sigma^2}\right) \right) \quad (16)$$

Mereka tidak akan mendapatkan gambar yang tersegmentasi, melainkan gambar yang setiap pikselnya mewakili kemiripan warna piksel

dan yang standar. Salah satu kelemahan metode ini adalah perhitungannya tidak linier.

### 2.1.4 Ruang YUV

Ruang YUV adalah model tiga komponen yang didasarkan pada pemisahan informasi luminansi dan krominansi:

$$\begin{aligned} Y &= 0,299R + 0,587G + 0,114B \\ U &= 0,493(B - Y) \\ V &= 0,877(R - Y) \end{aligned} \quad (17)$$

Panel informasi persegi panjang terdeteksi di [21] dengan ambang kolorimetri dalam YUV diikuti dengan proyeksi gradien horizontal dan vertikal pada pengenalan Kanji (sistem penulisan Jepang). Dalam pendekatan ini, kinerja hanya diilustrasikan dengan beberapa contoh. Pilihan di [22] juga jatuh pada ruang YUV setelah koreksi warna sebelumnya mengingat nilai piksel dari lantai abu-abu secara teoritis ( $R=G=B$ ).

Di dalam [23], penulis membandingkan metode segmentasi yang berbeda untuk menemukan metode terbaik di bidang pengenalan rambu jalan. Mereka mengklasifikasikan metode segmentasi menjadi tiga kategori utama: segmentasi dengan binarisasi, dekomposisi kromatik/akromatik, dan deteksi tepi dan kemudian mengusulkan metode segmentasi baru yang menggabungkan SVM dengan LUT (Look Up Table).

Setelah menerapkan berbagai metode dan melakukan penelitian ekstensif untuk menemukan metode terbaik, mereka menyimpulkan bahwa:

- Pada gambar tunggal, hasil terbaik diperoleh dengan metode RGB; namun, dalam video, hasil terbaik terlihat saat menerapkan metode LUT SVM;
- Deteksi tepi dapat digunakan sebagai pelengkap metode segmentasi namun tidak dapat digunakan sendiri;
- Standarisasi ruang warna RGB membuktikan kinerja yang baik dengan pengoperasian yang lebih sedikit; di sisi lain, ruang HSV, meskipun memberikan hasil yang lebih tinggi, memerlukan waktu eksekusi yang lama, sehingga metode ini kurang efisien. Jadi, mengapa kita menggunakan transformasi nonlinier jika normalisasi sederhana saja sudah cukup.

Berbeda dengan metode ambang batas warna dan ekstraksi wilayah ekstrem yang digunakan pada pendekatan sebelumnya, pendekatan terbaru [24] menggunakan Ekstraksi Wilayah Kontras Tinggi (HCRE), yang dimotivasi oleh metode deteksi berjenjang, untuk mengekstrak ROI dengan kontras lokal tinggi. Hal ini dapat menjaga kompromi antara tingkat deteksi dan ekstraksi. Memanfaatkan pengamatan bahwa berbagai jenis rambu lalu lintas memiliki kontras yang relatif tinggi di wilayah lokal, HCRE dapat menolak sekitar 83,10% rambu non-

wilayah menarik dengan kontras lokal rendah seperti langit, jalan raya, dan beberapa bangunan, sehingga meningkatkan kecepatan deteksi detektor pohon SFC dari 5 menjadi lebih dari 10 frame per detik dalam eksperimen mereka.

### 2.2 Metode berbasis bentuk

Penulis dalam pendekatan ini tidak sepenuhnya menganggap segmentasi warna sebagai ciri diskriminatif karena kepekaannya terhadap berbagai faktor seperti jarak target, kondisi cuaca, waktu, dan pantulan tanda. Sebaliknya, pendeteksian tanda dilakukan dari tepi citra yang dianalisis dengan pendekatan struktural atau komprehensif. Metode berbasis bentuk umumnya lebih kuat dibandingkan metode kolorimetri karena metode tersebut dapat memproses gambar dalam skala abu-abu dan menangani gradiennya. Namun, hal ini memerlukan waktu komputasi yang mahal, mengingat fakta bahwa kecepatan pemrosesan sangat bergantung pada jumlah tepi yang terdeteksi. Namun, metode berbasis bentuk dapat menangani gambar skala abu-abu; di beberapa negara, seperti Jepang, terdapat pasangan rambu berbeda dalam kode jalan raya yang, jika dikonversi ke skala abu-abu, akan tampak sama persis. Untuk dapat membedakannya, diperlukan sejumlah informasi warna [7]. Di sisi lain, beberapa penulis mengadopsi fitur warna untuk melokalisasi wilayah yang diinginkan dan melengkapinya dengan metode bentuk untuk mendeteksi posisi tanda dan mengenali bentuk geometrisnya.

Vitable dkk. [18] menggunakan totalitas piksel untuk mengenali bentuk geometris rambu, dimana setiap bentuk rambu jalan diwakili oleh gambar biner berukuran tetap ( $36 \times 36$  piksel). Setelah mendeteksi wilayah yang diinginkan dengan teknik agregasi dinamis piksel, mereka mengubah ukurannya pada skala gambar biner yang sama untuk menghitung ukuran kemiripan dengan semua bentuk rambu jalan menggunakan koefisien Tanimoto: Nilai koefisien ini dinormalisasi, yaitu, semakin mendekati 1, semakin mirip model dan wilayah yang diminati. Jika  $X$  dan  $Y$  dianggap kumpulan piksel gambar biner yang akan dibandingkan, maka koefisien Tanimoto  $S$  akan didefinisikan sebagai berikut:

$$S = \frac{|X \cap Y|}{|X \cup Y|} \quad (18)$$

Hasil yang diperoleh menunjukkan bahwa lebih dari 86% tanda terdeteksi di antara 620 gambar dari 24 kelas. Penulis di [25] menggunakan pencocokan template untuk memfilter wilayah yang tidak memiliki rambu lalu lintas. Jendela geser, yang memiliki ukuran templat yang sama, meluncur di atas gambar untuk mencari wilayah yang paling mirip. Fungsi kemiripan yang digunakan adalah mean square error (MSE).

$$UMK = \frac{1}{M \cdot N} \sum_{kamu=1}^N [T(x, kamu) - saya(x, y)]^2 \quad (19)$$

**Tabel 1** Hasil yang dicapai Youssef dkk. [81]

| Himpunan data | Terlalu tinggi |            | Bahaya      |            | Wajib       |            |
|---------------|----------------|------------|-------------|------------|-------------|------------|
|               | Akurasi (%)    | Waktu (md) | Akurasi (%) | Waktu (md) | Akurasi (%) | Waktu (md) |
| GTSDb         | 98.67          | 231        | 96.01       | 234        | 90.43       | 243        |
| DIT           | 97,87          | 198        | 98.12       | 197        | 89.71       | 200        |


- $T(x, kamu)$ : nilai intensitas gambar pola pada posisi  $(x, kamu)$ ;
- $saya(x, y)$ : intensitas gambar masukan pada posisi tersebut  $(x, kamu)$ ;
- $MDanN$ : masing-masing lebar dan tinggi gambar.

Transformasi Hough telah digunakan oleh [26] untuk mendeteksi tepi panel dan memilih kontur tertutup yang menjadikan pendekatannya sensitif terhadap kebisingan dan oklusi. Pendekatan ini mampu mendeteksi 97% dari 435 rambu batas kecepatan dan 94% dari 312 rambu bahaya dalam rentang waktu antara 20 dan 200 ms/img sesuai dengan jumlah outline yang diproses. Perlu disebutkan bahwa Miura dkk. [26] juga telah menerapkan transformasi Hough untuk sinyal melingkar.

Youssef dkk. [81] juga memilih untuk menggunakan deskriptor HOG dengan angka  $40 \times 40$  jendela deteksi (blok  $10 \times 10$  dan  $2 \times 2$  melangkah). Dataset GTSRB digunakan untuk pelatihan putaran pertama, DITS (The Data Set of Italian Traffic Signs) digunakan untuk putaran kedua, dan keduanya digunakan pada putaran ketiga. Untuk mengurangi positif palsu dan waktu eksekusi, langkah segmentasi warna dengan HSV yang ditingkatkan digunakan sebelum langkah deteksi. Hasil yang ditetapkan diilustrasikan dalam Tabel 1.

Di dalam [27], penulis lebih memilih menggunakan Transformasi Simetri Radial untuk mendeteksi tanda batas kecepatan. Metode ini, yang merupakan varian dari transformasi Hough sirkular, dibuat khusus untuk mendeteksi kemungkinan kemunculan tanda sirkular. Penulis mencapai tingkat deteksi sebesar 96% untuk 10% positif palsu dalam 50ms/img untuk gambar 320–240. Penulis di [28] juga menggunakan Transformasi Simetri Radial untuk mendeteksi bentuk geometris lainnya seperti segi delapan, persegi, dan segitiga. Namun, mereka mencapai tingkat deteksi 100% untuk bentuk segitiga, dan kelemahan utamanya adalah ia hanya dapat menemukan ukuran dan posisi bentuk: Ia tidak dapat membedakan panel yang lewat dan persimpangan.

Di dalam [29], dilakukan proses ekstraksi kontur dengan akurasi garis singgung terkait, dan mereka juga mengusulkan tiga algoritma: deteksi segi empat, elips, dan segitiga tipe RANSAC. Bentuk akhir akan dipilih berdasarkan derajat kompatibilitas yang diberikan oleh masing-masing algoritma. Metode yang disajikan dalam [30] diadopsi untuk memperkirakan pusat bentuk hanya dengan menggunakan tiga titik dengan garis singgungnya. Lebih dari 80% dari 1.400 gambar uji terdeteksi dengan benar, dengan 5% positif palsu, dalam waktu pemrosesan yang berkisar antara 15 dan 20 detik untuk gambar tahun 1980 1024.



**Gambar 2** CDT (WarnaTransformasi Jarak) dinormalisasi: A gambar asli secara diskrit warna, B CDT hitam, C CDT putih, D CDT merah. Daerah bayangan berarti jarak yang kecil, ekstrak [8] (gambar berwarna online)



Qin dkk. [31] memanfaatkan deskriptor Fourier (FD) untuk mendeskripsikan kontur, alasan utama penggunaan FD adalah ketahanannya terhadap rotasi, penskalaan, dan translasi, dan kemudian, proses pencocokan FD diterapkan. Basis data yang berisi lebih dari 20.000 gambar telah dibuat dengan merekam urutan lebih dari 350 km jalan raya dan jalan kota Swedia; database ini digunakan untuk mengevaluasi pendekatan yang diusulkan. Rata-rata tingkat deteksi yang dicapai adalah 77,08% dengan total 641 gambar.

Beberapa karya, seperti [8], lebih disukai menggunakan transformasi jarak yang mengubah gambar biner menjadi gambar di mana setiap nilai piksel mewakili jarak dari piksel ke fitur piksel terdekat. Para peneliti mengusulkan varian DT yang disebut Color Distance Transform (CDT) di mana mereka menerapkan perbandingan antara gambar asli dan gambar template dalam representasi warna diskrit. Untuk memudahkan perbandingan, mereka menghitung transformasi jarak DT untuk setiap warna diskrit. Kemudian, piksel yang memiliki warna diskrit dianggap sebagai piksel fitur sedangkan piksel lainnya tidak. Hasil dari proses ini diilustrasikan pada Gambar.2.

Qin dkk. [32] gunakan vektor jarak ke batas (DTB): Ini adalah jarak antara kontur luar dan kotak pembatas tempat mereka menghitung, untuk setiap gumpalan tersegmentasi, empat vektor DTB (kiri, kanan, atas, dan bawah) sebagai ditunjukkan pada Gambar.3. Jarak ini kuat untuk translasi dan rotasi. Karena gumpalan harus diperbesar menjadi  $36 \times 36$ , pendekatan yang diusulkan tidak kuat untuk mengukur perubahan. Vektor DTB kemudian akan dipilih sebagai fitur untuk mengklasifikasikan blob dengan SVM. Penggunaan empat vektor jarak untuk setiap blob tersegmentasi membuat DTB kuat terhadap oklusi, oleh karena itu DTB juga digunakan oleh [63] sebagai fitur untuk mengenali bentuk geometris tanda.

Pendekatan lain diusulkan oleh [11] mengenali bentuk calon tanda; idenya adalah membandingkan pola yang terdeteksi dengan persegi panjang BoxOut yang melingkupinya. Skor persimpangan dihitung antara kontur

**Gambar 3** Jarak ke perbatasan (DTB) Agumpalan tersegmentasi, B gambar biner dari A, CDTB gumpalan [32]



**Gambar 4** Pendekatan deteksi yang diusulkan [11] A persegi panjang, B segi tiga, C lingkaran, D segi delapan

pola dan empat baris BoxOut; itu ditunjukkan pada Gambar.4. Pendekatan ini mampu mendeteksi 95,65% dengan 2,17% alarm palsu. Dataset yang digunakan terdiri dari 48 gambar dengan ukuran 360×270 piksel berisi tiga rambu lalu lintas berbeda. Kerugian dari pendekatan ini adalah kelemahannya terhadap oklusi dan kebisingan.

Baru-baru ini, algoritma deteksi lingkaran baru EDCircles [75] digunakan oleh [76] untuk mendeteksi rambu lalu lintas melingkar. Algoritmenya terdiri dari, pertama, menggunakan Edge Drawing Parameter Free (EDPF) untuk mendeteksi tepi pada gambar skala abu-abu, kemudian mengekstrak busur lingkaran dari tepi dan menggabungkan busur yang memiliki radius serupa, dan terakhir, kandidat lingkaran divalidasi. Tingkat akurasi deteksi yang dicapai oleh dataset GTSDb adalah 93,78% dengan 0,99% positif palsu untuk rambu larangan dan 75,51% dengan 2,04% positif palsu untuk rambu wajib.

Meja 2 merangkum metode berbasis bentuk; terlihat jelas dari tabel bahwa metode deteksi sebelumnya tidak menggunakan database yang sama, sehingga mencegah kita untuk membandingkannya satu sama lain. Penulis di [29] menggunakan kumpulan data besar dengan gambar besar, mencapai tingkat deteksi yang dapat diterima yang masih sangat jauh dari aplikasi real-time. Metode yang digunakan oleh [11], namun karena bersifat real-time, kumpulan datanya kecil, sehingga kami tidak dapat menganggapnya sebagai metode yang sangat efisien.

### 2.3 Metode berbasis pembelajaran

Metode sebelumnya memiliki kelemahan yang sama pada beberapa faktor seperti perubahan pencahayaan, oklusi, perubahan skala, rotasi, dan translasi. Namun, masalah ini juga dapat diatasi dengan menggunakan pembelajaran mesin, namun memerlukan database data beranotasi yang besar.

Detektor kaskade yang meningkatkan kompleksitas digunakan oleh Viola dan Jones [33], setiap detektor adalah sekumpulan pengklasifikasi berdasarkan wavelet Haar, dan pengklasifikasi ini menggunakan algoritma pembelajaran AdaBoost.

Penulis di [34] menggunakan detektor Viola – Jones untuk mendeteksi rambu lalu lintas berbentuk segitiga. Detektor dilatih menggunakan sekitar 1000 gambar dengan kualitas yang relatif buruk. Detektor yang diperoleh mencapai tingkat positif sebenarnya yang sangat tinggi (berkisar antara 90 hingga 96%) tergantung pada set pelatihan dan konfigurasi detektor. Dalam percobaan mereka [34,35], mereka mengamati dua kelemahan utama detektor Viola – Jones:

- kebutuhan sejumlah besar gambar pelatihan;
- tingkat positif palsu.

Namun demikian, penelitian mereka juga menunjukkan bahwa detektor Viola–Jones tahan terhadap kebisingan dan data pelatihan berkualitas rendah [36].



**Meja 2** Metode deteksi berbasis bentuk

| Kertas                   | Metode deteksi                        | Tingkat deteksi (%)                                   | Alarm palsu                                           | Kumpulan data yang digunakan                  | Waktu                                                    |
|--------------------------|---------------------------------------|-------------------------------------------------------|-------------------------------------------------------|-----------------------------------------------|----------------------------------------------------------|
| Barnes dkk. [27]         | Simetri radial transformasi           | 100                                                   | 10                                                    | Rambu batas kecepatan dengan 320×240 piksel   | 50 mdtk/gambar                                           |
| Behloul dkk. [11]        | Skor persimpangan dengan kotak keluar | 95,65                                                 | 2,17%                                                 | 48 gambar dengan 360×270 piksel1              | Tidak melebihi 1 ms/gambar                               |
| Berkaya dkk. [76]        | Lingkaran EDC                         | 93,78 untuk rambu larangan<br>75,51 untuk rambu wajib | 0,99% untuk rambu larangan<br>2,04% untuk rambu wajib | GTSD                                          | 36 mdtk/gambar                                           |
| Garcia-Garrido dkk. [26] | Transformasi yang hebat               | 97 batas kecepatan<br>94 panel bahaya 80              | -                                                     | 435 rambu batas kecepatan<br>312 rambu bahaya | 20 hingga 200 ms/img                                     |
| Soheilian dkk. [29]      | 3 Algoritma yang diusulkan            | 86                                                    | 5                                                     | 1400 gambar dengan tahun 1980×1024 piksel     | 15 hingga 20 dtk/img                                     |
| Vitable dkk. [18]        | Jarak kesamaan                        | Larangan: 98,67<br>Bahaya: 96,01<br>Wajib: 90,43      | -                                                     | 620 img dengan 24 kelas                       | -                                                        |
| Youssef dkk. [81]        | BABI                                  | Larangan: 97,87<br>Bahaya: 98,12<br>Wajib: 89,71      | -                                                     | GTSD                                          | 231 md<br>234 ms<br>243 ms<br>198 ms<br>197 ms<br>200 ms |
|                          |                                       |                                                       |                                                       | DIT                                           |                                                          |

Barrio dkk. [37] mengusulkan kaskade perhatian yang terdiri dari sekumpulan pengklasifikasi di mana setiap entri kaskade adalah wilayah minat yang terdeteksi oleh pengklasifikasi sebelumnya, dan algoritma Adaboost digunakan untuk mempelajari pengklasifikasi. Para peneliti juga mengusulkan strategi klasifikasi Forest-ECOC (Error Correcting Output Codes) untuk mengatasi masalah multikelas, dan idenya adalah dengan mengintegrasikan beberapa pohon dalam Framework ECOC. Penulis memperoleh hasil sebagai berikut:

- Lingkaran larangan: 70% deteksi dengan 3,65% positif palsu per gambar;
- Lingkaran kewajiban: 60% deteksi dengan 0,95% positif palsu per gambar;
- Segitiga bahaya: 65% deteksi dengan 2,25% positif palsu per gambar;
- Segitiga Kanan Jalan: 75% deteksi dengan 2,8% positif palsu per gambar.

Tingkat pengobatan tidak diberikan karena algoritma dioperasikan secara offline. Kasus panel persegi panjang tidak dibahas, dan informasi warna tidak digunakan.

Priscariu dkk. [38] menggunakan pengklasifikasi Adaboost berdasarkan detektor viola dan Jones, diikuti oleh SVM yang beroperasi pada saluran RGB yang dinormalisasi. Sistem ini kuat terhadap keburaman gerakan melalui pelacakan berbasis wilayah 3D.

Chen dkk. [85] meneliti eksplorasi Adaboost dan dukungan regresi vektor (SVR) bersama-sama untuk mendeteksi rambu lalu lintas. Pendekatan yang diusulkan dievaluasi melalui tiga kumpulan data (GTSD, BTSD, STSD) menggunakan Intel Core-i7 4770 dengan RAM 8G. Pendekatan ini bukan waktu nyata, waktu deteksi bervariasi dari 0,05 hingga 0,5 detik, dan waktu pelatihan adalah 16 menit. Recall yang diperoleh pada STSD adalah 80,85% dengan presisi 94,52%, dan Tabel 3 menunjukkan hasil yang dicapai pada GTSD dan BTSD.

Peneliti di [19] menggunakan algoritma genetika pada langkah deteksi. Penulis menerapkan pencarian paralel dalam arah yang berbeda diikuti dengan proses optimasi yang meniru evolusi dan seleksi alam. Namun, pendekatan mereka kuat terhadap perubahan skala, rotasi, kondisi cuaca, dan oklusi parsial, dan ini bukan aplikasi real-time. Jaringan saraf digunakan oleh [39] untuk mengenali bentuk panel, namun proses ini tidak linier dengan waktu 2s/img.

**Tabel 3** Hasil yang dicapai pada GTSD dan BTSD oleh Chen et al. [85]

| Kategori              | GTSD (%) | BTSD (%) |
|-----------------------|----------|----------|
| Wajib                 | 99,87    | 97,78    |
| Bahaya                | 100      | 99,88    |
| Yg menjadi penghalang | 100      | 93,45    |

**Tabel 4** Tingkat deteksi algoritma yang dikutip dalam Houben et al. [43]

| Algoritma     | Larangan (%) | Peringatan (%) | Wajib (%) |
|---------------|--------------|----------------|-----------|
| HOG+LDA       | 91.3         | 90.7           | 69.2      |
| Seperti Hough | 55.3         | 65.1           | 34.7      |
| Viola-Jones   | 98.8         | 74.6           | 67.3      |

Zaklouta dkk. [40] gunakan histogram gradien berorientasi, yang diusulkan oleh Dalal dan Triggs [41] untuk deteksi pejalan kaki karena invariansi skala, normalisasi kontras lokal, pengelompokan spasial yang kasar, dan orientasi gradien berbobot. Deskriptor HOG dihitung dan digunakan sebagai fitur untuk melatih pengklasifikasi SVM linier. Untuk meningkatkan presisi detektor SVM, mereka menggunakan operator morfologi (blackhat) untuk menyaring kandidat yang terdeteksi. Transformasi blackhat didefinisikan sebagai selisih antara gambar penutup dan gambar masukan. Sebagian besar gambar dihilangkan menggunakan filter ini, dan jumlah alarm palsu berkurang.

Trafo HOG juga digunakan oleh Wang dkk. [42], dan mereka menggunakan LDA dan SVM sebagai pengklasifikasi. Pendekatan yang diusulkan mencapai rasio recall dan presisi yang tinggi dalam kumpulan data GtSDB, tahan terhadap kondisi pencahayaan buruk, oklusi parsial, kualitas rendah, dan deformasi proyektif kecil, namun metode ini tidak bersifat real-time.

Di dalam [43], penulis menggunakan Tolok Ukur Deteksi Rambu Lalu Lintas Jerman yang dipresentasikan sebagai kompetisi di IJCNN2013 (Konferensi Gabungan Internasional tentang Jaringan Neural) untuk mengevaluasi beberapa pendekatan deteksi paling populer seperti detektor Viola-Jones berdasarkan fitur Haar dan pengklasifikasi linier yang mengandalkan deskriptor HOG, dan mereka juga mengevaluasi algoritma terbaru yang mengeksploitasi bentuk dan warna dalam skema pemungutan suara mirip Hough berbasis model yang disajikan di [44]. Kecepatan deteksi ketiga algoritma disajikan pada Tabel 4.

Salti dkk. [84] mengusulkan pendekatan berdasarkan ekstraksi wilayah kepentingan daripada deteksi jendela geser. Penulis menguji pendekatan mereka pada kumpulan data kebenaran dasar yang berisi 6580 gambar. Kumpulan data dibuat dengan menggunakan 5 kamera untuk melakukan geo-referensi tanda dengan benar; namun, menggunakan 5 kamera tidak praktis untuk aplikasi real-time karena akan menambah waktu eksekusi (Alih-alih memproses 1 gambar, 5 gambar akan diproses). Mereka mencapai 78,21% untuk rambu larangan, 82,13% untuk rambu bahaya, dan 72,78% untuk rambu wajib.

Detektor Fitur Saluran Integral yang dibangun berdasarkan fitur HOG dan pohon keputusan yang ditingkatkan digunakan oleh [45], pada dataset BTSD diperoleh 97,96% untuk rambu wajib, 97,40% untuk rambu peringatan, dan 94,44% untuk rambu larangan, pada dataset GTSDDB diperoleh 96,98% untuk rambu wajib, 100% untuk rambu peringatan, dan 100% untuk rambu larangan.

Untuk mengatasi masalah deteksi rambu lalu lintas (TSD) multikelas, [48] menyajikan kerangka lokalisasi rambu lalu lintas

yang mampu mendeteksi rambu lalu lintas multikelas dengan cepat pada citra resolusi tinggi. Mereka mengusulkan tiga ide baru: pertama, pola biner lokal ternormalisasi multi-blok (MN-LBP) dan MN-LBP miring (TMN-LBP) digunakan sebagai fitur diskriminan untuk mengekspresikan rambu lalu lintas multikelas secara efektif. Kedua, dirancang struktur pohon yang disebut Split-Flow Cascade. Ia menggunakan fitur-fitur umum dari beberapa kelas untuk membangun struktur piramida kasar hingga halus yang disebut pohon SFC. Ketiga, untuk merancang pohon SFC yang efisien, Common-Finder AdaBoost (CF AdaBoost) dikembangkan untuk menemukan fitur umum di antara set pelatihan yang berbeda. Semua kontribusi baru ini membuat sistem bekerja secara real time dengan recall yang tinggi, dan memberikan hasil yang baik pada dataset GTSDDB: 100% untuk rambu larangan, 99,2% untuk rambu peringatan, 98,57% untuk rambu wajib, dan 97,24% untuk tanda lainnya.

Di dalam [47], waktu pengoperasian yang baik telah tercapai (6–8 fps pada rangkaian video). Solusinya menghadirkan pendekatan baru, yang disebut Pohon Kategori-Pertama yang Ditugaskan (CFA-Tree) di mana mereka mengintegrasikan fase deteksi dan klasifikasi dalam satu modul, sistem baru ini memiliki akurasi tinggi sekitar 93,5%, namun pohon pencarian ini hanya bisa mendeteksi tiga kategori dan memiliki efisiensi rendah dalam menangani gambar resolusi tinggi [48].

Karena keberhasilan CNN dalam klasifikasi rambu lalu lintas, penulis di [77] mengusulkan ConvNet yang ringan dan dioptimalkan dengan jendela geser untuk mendeteksi rambu lalu lintas dalam gambar resolusi tinggi. Tingkat akurasi deteksi yang dicapai adalah 99,89% pada dataset German Traffic Sign Detection Benchmark. Waktu eksekusi pada GPU (GeForce GTX 980) adalah 26.506ms yang setara dengan pemrosesan 3772 frame per s. Hasil yang diperoleh membuat pendekatan ini menjadi aplikasi real-time.

Wu dkk. [46] menggunakan jaringan saraf konvolusional CNN untuk melokalisasi dan mengenali rambu lalu lintas, pertama mereka menggunakan mesin vektor pendukung untuk mengubah gambar asli dari RGB ke skala abu-abu untuk menghindari masalah sensitivitas terhadap perbedaan warna karena berbagai kondisi pencahayaan, kedua mereka menggunakan tetap lapisan di CNN untuk melokalisasi wilayah yang diminati yang mirip dengan rambu lalu lintas, dan lapisan yang dapat dipelajari digunakan untuk mengekstrak fitur diskriminan untuk klasifikasi. Mereka menggunakan GTSDDB sebagai kumpulan data dan memperoleh 99,73% untuk rambu peringatan dan 97,62% untuk rambu wajib, namun masih terlalu jauh untuk diterapkan secara real-time.

Jaringan saraf konvolusional bertingkat (CNN) baru-baru ini digunakan oleh [83] untuk mengurangi wilayah positif palsu yang terdeteksi menggunakan detektor fitur pola biner lokal (LBP) yang dikombinasikan dengan pengklasifikasi AdaBoost. Hasil yang dicapai pada GTSDDB menggunakan Intel Core 2 Duo 2.2GHz diilustrasikan dalam Tabel 5.

Di meja 7, kami melanjutkan metode deteksi berdasarkan pembelajaran mesin. Akurasi terbaik (>99%) dicapai oleh [84], [45] Dan [42], namun, apakah metode ini benar-benar dapat diterapkan secara komersial dan memiliki tingkat serta presisi yang tinggi dalam kebenaran lapangan dengan kondisi kompleks lainnya? Namun,



**Tabel 5** Hasil yang dicapai oleh Zang dkk. [83]

| Kategori              | Kecepatan (%) | Waktu (md) | Positif palsu |
|-----------------------|---------------|------------|---------------|
| YG MENJADI PENGHALANG | 99,45         | 35         | 1             |
| WAJIB                 | 96,50         | 34         | 0             |
| BAHAYA                | 98,33         | 35         | 0             |

metode ini memberikan hasil terbaik, dan tidak diterapkan secara real-time. Di samping itu, [82] mencapai hasil yang baik dengan eksekusi waktu nyata (35 ms). Biasanya, sebagian besar metode deteksi berbasis pembelajaran mencapai tingkat deteksi lebih tinggi dari 95%, jadi inilah saatnya membuat kumpulan data baru yang lebih rumit karena kumpulan data saat ini sudah jenuh.

#### 2.4 Kumpulan data deteksi yang tersedia untuk umum

- Tolok Ukur Deteksi Rambu Lalu Lintas Jerman—kumpulan data GTSDDB [43]: GTSDDB adalah deteksi rambu lalu lintas satu gambar, terdiri dari 900 gambar 1360×800 piksel dibagi menjadi 600 gambar pelatihan dan 300 gambar evaluasi, dan diklasifikasikan menjadi tiga kelas wajib, peringatan, dan larangan. Hal ini memungkinkan sistem evaluasi online dengan analisis langsung dan pemeringkatan hasil yang dikirimkan.
- Kumpulan Data Rambu Lalu Lintas Belgia—kumpulan data BTSD: BTSD [49]: Terdiri dari lebih dari 10.000 anotasi, dan gambar dibagi menjadi tiga kategori wajib, peringatan, dan larangan. Ini berisi empat rangkaian video yang diambil di Belgia yang dapat digunakan untuk eksperimen pelacakan.
- Laboratorium Mobil Cerdas dan Aman—dataset LISA [50]: Berisi video dan bingkai beranotasi, terdiri dari 7855 gambar berisi 47 kategori rambu lalu lintas, dan hanya 6610 gambar yang diberi anotasi, dan ukuran gambar bervariasi dari 640×480 hingga 1024×522.
- Kumpulan data STSD (Kumpulan Data Rambu Lalu Lintas Swedia) [31]: Ini terdiri dari lebih dari 20.000 gambar yang dibuat dengan mengambil rekaman di lebih dari 350 km jalan raya dan jalan kota Swedia, dan setiap frame kelima dari urutan tersebut dianotasi secara manual. Urutan STSD dapat digunakan untuk aplikasi pelacakan.
- Data DITS (Kumpulan Data Rambu Lalu Lintas Italia) [81]: Ini adalah kumpulan data terbaru yang dihasilkan dari 43.289 gambar yang diekstraksi dari video berdurasi 14 jam (1280×720 pada 10fps) ditangkap di Italia pada tanggal dan malam hari. Kumpulan data deteksi terdiri dari 1416 gambar pelatihan dan 471 gambar uji, juga berisi file teks dengan anotasi, dan tiga kelas super berbasis bentuk ditentukan: Larangan, Indikasi, dan Peringatan.

Dataset deteksi rambu lalu lintas dirangkum dalam Tabel 6.

**Tabel 6** Kumpulan data deteksi rambu lalu lintas yang tersedia untuk umum

| Himpunan data | Gambar-gambar | Properti                                                                                    |
|---------------|---------------|---------------------------------------------------------------------------------------------|
| GTSDDB [43]   | 900           | Ukuran gambar: 1360×800 piksel<br>Negara: Jerman                                            |
| BTSD [49]     | 10,000        | Ukuran gambar: 1628×1236 piksel<br>Berisi 4 video Dengan anotasi Negara: Belgia             |
| LISA [50]     | 7855          | Berisi video Dengan anotasi<br>Ukuran gambar: 640×480<br>hingga 1024×522 Negara: AS         |
| MASTIF [51]   | 10,000        | Ukuran gambar: 720×piksel<br>Terdiri dari 3 kumpulan data<br>Dengan anotasi Negara: Kroasia |
| STSD [31]     | 20,000        | Ukuran gambar: 1280×960 piksel<br>Dengan anotasi Negara: Swedia                             |
| DIT [81]      | 1887          | Dengan anotasi Negara: Italia                                                               |

### 3 Metode klasifikasi

Pada bagian ini, kami menyoroti beberapa metode terkini dan efisien dalam klasifikasi rambu lalu lintas. Pertama, kami menjelaskan beberapa metode menggunakan fitur kerajinan tangan seperti HOG, LBP, SIFT, dan BRISK; kedua, disebutkan metode pembelajaran mendalam yang melampaui kinerja manusia (Tabel 7).

#### 3.1 Metode pembelajaran berdasarkan ciri-ciri kerajinan tangan

Fatin Zaklouta dkk. [52] menggunakan deskriptor histogram orientasi gradien (HOG) dengan ukuran berbeda dan Transformasi Jarak untuk mengevaluasi kinerja pohon Kd dan hutan acak, dan hutan acak lebih tahan terhadap variasi latar belakang dibandingkan pohon K-d. Tingkat klasifikasi yang dicapai untuk hutan acak adalah 97,2% dengan deskriptor HOG dan 81,8% dengan Transformasi Jarak, pohon K-d meningkat masing-masing sebesar 92,9 dan 67%.

Ellahyani dkk. [86] menghitung fitur histogram gradien berorientasi (HOG) dalam ruang warna HSI; kemudian dikombinasikan dengan fitur kesamaan diri lokal (LSS). Penulis lebih suka menggunakan hutan acak sebagai pengklasifikasi. Tingkat pengenalan yang dicapai adalah 97,43% pada GTSDDB dan 94,21% untuk keseluruhan sistem dalam 8–10 frame/s.

Penulis di [53] membandingkan kinerja pengenalan rambu lalu lintas metode pembelajaran manusia dan mesin; mereka juga menunjukkan hasil pengklasifikasi linier yang dilatih dengan analisis diskriminan linier (LDA). Performa LDA bergantung pada representasi fitur. Penulis mencapai hasil terbaik dengan representasi HOG2 dengan akurasi 95,68, 93,18% untuk HOG1 dan 92,34% untuk HOG3.

Analisis data pelatihan dilakukan oleh [62] menunjukkan adanya ketimpangan distribusi sampel pada kelas rambu lalu lintas. Kelas terbesar dapat memuat lebih banyak

**Tabel 7** Metode deteksi berbasis pembelajaran

| Metode                                       | Kumpulan data yang digunakan | Tanda-tanda larangan           | Tanda peringatan                      | Tanda-tanda wajib    | Semua tanda | Waktu                  |
|----------------------------------------------|------------------------------|--------------------------------|---------------------------------------|----------------------|-------------|------------------------|
| Aghdam dkk. [77]                             | GTSD                         |                                | –                                     | –                    | 99,89%      | 26,506 ms              |
| Bar dkk. [37] Brkic dkk. [34] Chen dkk. [85] | –<br>1000 gambar<br>STSD     | 70% dengan 3,65% positif palsu | 65% dengan FP 2,25% 90%<br>hingga 96% | 60% dengan FP 0,95%. | –           | –                      |
|                                              | GTSD                         | 100%                           | 100%                                  | 99,87%               | 80,85%      | –                      |
|                                              | BTSD                         | 97,78%                         | 99,88%                                | 93,45%               | –           | 0,05 hingga 0,5 detik  |
| Houben dkk. [43]                             |                              |                                |                                       |                      |             |                        |
| HOG+LDA                                      | GTSD                         | 91,3%                          | 90,7%                                 | 69,2%                | –           | –                      |
| Seperti Hough                                | GTSD                         | 55,3%                          | 65,1%                                 | 34,7%                | –           | –                      |
| Viola-Jones                                  | GTSD                         | 98,8%                          | 74,6%                                 | 67,3%                | –           | –                      |
| Liu dkk. [47]                                | GTSD                         | –                              | –                                     | –                    | 93,5%       | Waktu sebenarnya       |
| Liu [48]                                     | GTSD                         | 100%                           | 92,2%                                 | 98,57%               | –           | 192 ms                 |
| Mathias dkk. [45]                            | BTSD                         | 94,44%                         | 97,40%                                | 97,96%               | –           | –                      |
|                                              | GTSD                         | 100%                           | 100%                                  | 96,98%               | –           | –                      |
| Salti dkk. [84]                              | Kebenaran dasar              | 78,21%                         | 82,13%                                | 72,78%               | –           | –                      |
| Wang dkk. [42]                               | GTSD                         | 99,88%                         | 99,85%                                | 99,85%               | –           | 1,12 hingga 1,48 detik |
| Zaklouta dkk. [40]                           | 820 gambar berisi 11 kelas   | –                              | –                                     | –                    | 95%         | 247 ms                 |
| Zang dkk. [83]                               | GTSD                         | 99,45%                         | 98,33%                                | 96,50%               | –           | 35 ms                  |

dari 1000 gambar sedangkan kelas terkecil hanya dapat memuat beberapa gambar. Ketidakseimbangan ini dapat berdampak negatif pada kinerja klasifikasi; untuk mengatasi permasalahan tersebut, penulis mengusulkan metode klasifikasi hierarki untuk pengenalan rambu lalu lintas, dan pohon klasifikasi terdiri dari dua lapisan. Pada lapisan pertama, pengklasifikasi Adaboost dikombinasikan dengan Fitur Saluran Agregat (ACF) digunakan untuk mengklasifikasikan nyanyian ke dalam tiga kategori menurut bentuk geometrisnya. ACF digunakan untuk representasi fitur yang menggunakan 10 saluran (tiga saluran warna ruang warna RGB, besaran gradien, enam peta gradien berorientasi: horizontal, vertikal, 30, 60, 120, dan 150), dan kemudian, fitur-fitur ini digunakan untuk melatih pengklasifikasi Adaboost. Pada lapisan kedua, rambu lalu lintas diidentifikasi oleh pengklasifikasi hutan acak yang dilatih pada tiga fitur: histogram gradien berorientasi (HOG), pola biner lokal (LBP), dan HSV; akurasi mencapai 95,97% dengan dataset GTSRB dan 97,94% dengan dataset STSD.

Yakimov dkk. [61] mencapai pengenalan rambu lalu lintas secara real-time menggunakan teknologi pemrograman multithread CUDA pada GPU seluler Nvidia Tegra K1, yang berisi 192 inti grafis dan 4 inti CPU arsitektur ARM. Para penulis mengusulkan algoritma transformasi Hough umum (GHT) yang dimodifikasi untuk mengklasifikasikan rambu lalu lintas, dan mereka menunjukkan bahwa algoritma tersebut mencapai kompromi yang baik antara waktu eksekusi dan akurasi dengan gambar yang telah diproses sebelumnya dibandingkan dengan hasil yang diperoleh dalam [43] seperti yang diilustrasikan pada Tabel 8. Kumpulan data rambu lalu lintas Jerman digunakan, tetapi hanya 9987 dari 50.000 gambar yang diperhitungkan.

Fitur LBP dan HOG digunakan oleh Li et al. [74] untuk mengenali rambu lalu lintas. Tingkat akurasi yang dicapai sebesar 95,16% untuk HOG dan 95,38% untuk LBP dengan dataset GTSRB. Penulis di [76] menggunakan tiga kategori deskriptor fitur HOG, LBP, dan filter Gabor sebagai fitur input ke SVM, hasil yang diperoleh ditunjukkan pada Tabel 9.

Dia dan Dai [72] mengusulkan varian baru pola biner lokal (LBP) bernama pola biner lokal simetris pusat multiskala (MS-CSLBP) yang digunakan sebagai fitur lokal dan koefisien frekuensi rendah transformasi wavelet diskrit (DWT) sebagai fitur global untuk rambu lalu lintas terklasifikasi. Perbedaan besar antara LBP dan CSLBP adalah CSLBP menggantikan nilai piksel tengah dengan nilai piksel yang simetris dengan

**Tabel 9** Hasil yang dicapai oleh Li dkk. [74]

| mendekati         | Kecepatan (%) | Eksekusi waktu (md) |
|-------------------|---------------|---------------------|
| LBP               | 93.36         | 1.21                |
| Gabor             | 93,90         | 2.31                |
| BABI              | 94.56         | 0,02                |
| HOG+LBP           | 95.24         | 1.24                |
| HOG + Gabor       | 97.00         | 2.40                |
| Gabor+LBP         | 95.17         | 3.49                |
| Gabor + LBP + HOG | 97.04         | 3.60                |

piksel tengah yang mengurangi dimensi vektor fitur menjadi 2  $\sqrt{2}$  daripada 2  $\sqrt{d}$  di LBP seperti yang diilustrasikan pada persamaan berikut:

$$CSLBP_N = \sum_{S=0}^{N-1} S(g_{S_{sayar}} - g_{S_{sayar+P/2}}) / 2^{S_{sayar}} \quad (20)$$

$$S(x) = \begin{cases} 1 & x > \tau \\ 0 & x < \tau \end{cases}$$

Sebuah ambang batas digunakan untuk mengurangi pengaruh kebisingan. CSLBP dapat mengurangi dimensi vektor fitur dan menghitung dengan sangat sederhana dibandingkan dengan HOG dan SIFT; namun, fitur CSLBP skala tunggal tidak cukup sebagai fitur pembeda untuk mewakili rambu lalu lintas. Untuk mengatasi masalah tersebut, penulis mengusulkan untuk menghitung CSLBP secara multiskala (radius = 1, 2 dan 3). MS-CSLBP kemudian digunakan sebagai fitur input untuk mengklasifikasikan rambu lalu lintas dengan SVM; hasil yang dicapai oleh [72] dengan dataset GTSRB dibandingkan dengan dua algoritma [73] seperti yang ditunjukkan pada Tabel 10

Algoritma pencocokan fitur SIFT digunakan oleh [66], dan penulis menguji pendekatan mereka pada delapan video yang diambil di India. Kisaran angka yang dicapai adalah antara 75 hingga 100% dengan false positif tidak melebihi 2%. Hua dkk. [67] juga menggunakan SIFT yang dikombinasikan dengan bag of visual untuk membuat codebook kemudian mengklasifikasikannya dengan SVM. Dataset yang digunakan untuk evaluasi terdiri dari 130 gambar (50×50 piksel), dan memperoleh tingkat akurasi 93% dengan waktu eksekusi sebesar 0,098ms per gambar. Untuk mengeksploitasi struktur intrinsik

**Tabel 8** Hasil yang dicapai oleh Yakimov [61]

| Algoritma                      | Akurasi (%) | waktu (FPS) |
|--------------------------------|-------------|-------------|
| Jendela geser + SVM [43] GHT   | 100         | 1           |
| dengan pra-pemrosesan [61] GHT | 97.3        | 43          |
| tanpa pemrosesan awal [61]     | 89.3        | 25          |
| Viola-Jones [43] BABI [43]     | 90,81       | 15          |
|                                | 70.33       | 20          |

**Tabel 10** Hasil yang dicapai oleh He dkk. [72] dibandingkan dengan hasil Tang et al. [73]

| metode           | Kecepatan (%) | Eksekusi waktu (md) |
|------------------|---------------|---------------------|
| BABI [73]        | 95,92         | 134                 |
| DCT+LBP [73]     | 92,50         | 350                 |
| DWT+MSCSLBP [72] | 97,67         | 121                 |

buku kode visual yang telah dipelajari sebelumnya, pendekatan fitur baru menggunakan pengkodean renggang kelompok diusulkan oleh [71]. Tingkat pengenalan yang dicapai oleh pendekatan yang diusulkan adalah 97,83% dengan dataset GTSRB.

[63] menggunakan Speeded Up Robust Feature Descriptor (SURF) dengan pengklasifikasi Artificial Neural Network (ANN) untuk mengenali rambu lalu lintas. Mereka membuat kumpulan data baru yang berisi 200 gambar yang diambil dari jalan raya Bangladesh dalam kondisi cuaca dan pencahayaan yang berbeda. Tingkat positif sebenarnya yang dicapai adalah 97% dengan tingkat positif palsu 3%; Namun, hasilnya bagus, waktu pelaksanaannya tidak disebutkan, dan kumpulan datanya tidak berisi semua jenis rambu lalu lintas.

[64] menggabungkan SURF dengan K-tetangga terdekat (K-NN) metode pencarian, dan mereka mengusulkan strategi pemilihan fitur baru. Poin kepentingan yang tidak berguna dihilangkan dengan menerapkan ambang batas determinan matriks Hessian, hanya poin kepentingan dengan determinan lebih besar yang dipertimbangkan. Untuk menemukan kecocokan yang baik, mereka mengusulkan strategi pemilihan fitur baru dengan menghitung jarak minimum pertama dan kedua. Kemudian, kecocokan yang baik diberikan sebagai berikut:

$$\frac{D_1}{2} < T_1 \text{ dan } d_1 < t_d \quad (21)$$

$D_1, D_2$ : jarak minimum pertama dan kedua.  $T_1, T_2$ : masing-masing ambang relatif dan absolut.

Untuk mengevaluasi pendekatan mereka, mereka membuat kumpulan data baru yang mencakup lebih dari 1.200 gambar. Mereka memiliki total pengakuan salah 12,81% dan tingkat klasifikasi salah 0,99%. Pendekatan yang diusulkan tidak kuat terhadap keburaman, dan mereka memperoleh total pengenalan salah sebesar 4% setelah menghilangkan gambar buram dari kumpulan data.

Chen dkk. [69] menggunakan SURF sebagai fitur untuk mengklasifikasikan rambu lalu lintas; pertama, mereka membagi tanda templat menjadi delapan kategori berdasarkan warna dan pengklasifikasi AdaBoost yang terlatih untuk mengurangi waktu pemrosesan. Kemudian algoritma Approach Nearest Neighbor (ANN) digunakan untuk langkah pencocokan. Akurasi pengenalan yang dicapai sebesar 92,7% dengan 200 gambar yang berisi 281 rambu lalu lintas.

Deskriptor SURF juga dipilih oleh [11] karena efisiensi SURF dalam waktu eksekusi dan ketahanan terhadap perubahan pencahayaan dibandingkan dengan SIFT dan PCA-SIFT. Penulis membuat model templat untuk setiap kelas tanda untuk menghilangkan titik-titik menarik yang terdeteksi di latar belakang dan hanya mempertahankan titik-titik di dalam tanda. Tingkat pengenalan yang diperoleh sebesar 97,72% dengan jumlah gambar sebanyak 48 gambar.

Hoferlin dkk. [70] menyajikan arsitektur untuk pengenalan rambu lalu lintas melingkar; itu terdiri dari dua perceptron multilayer (MLP). Lapisan pertama menggunakan SIFT sebagai fitur masukan, dan lapisan kedua menggunakan SURF. Kinerja sistem dievaluasi dalam urutan 30 menit yang berisi 133 rambu lalu lintas, dan mencapai tingkat 96,4%.

**Tabel 11** Hasil yang dicapai oleh Malik dkk. [65]

| metode      | Tingkat pengakuan (%) |                | Waktu yang cocok |
|-------------|-----------------------|----------------|------------------|
|             | Skenario 1 (%)        | Skenario 2 (%) |                  |
| MENYARING   | 100                   | 93,75          | 9.03             |
| BERSELANCAR | 93,75                 | 81.25          | 6.02             |
| CEPAT       | 93,75                 | 87,5%          | 4.3              |

Analisis perbandingan tiga poin teknik pencocokan fitur SIFT, SURF dan Binary Robust Invariant Scalable Key (BRISK) disajikan oleh [65]. Penulis membuat dataset baru yang berisi 172 gambar yang diklasifikasikan ke dalam 32 kategori; setelah evaluasi, mereka mengamati bahwa SIFT mengungguli SURF dan BRISK. Namun dalam waktu eksekusi, BRISK hampir dua kali lebih cepat dari SIFT, namun tidak secara real time. Penulis mengevaluasi sistem dalam dua skenario yang berbeda: pada skenario pertama, tanda-tanda disegmentasi secara manual, sedangkan pada skenario kedua, tanda-tanda merupakan hasil dari langkah segmentasi. Meja 11 menunjukkan hasil yang diperoleh penulis yang menunjukkan bahwa kinerja klasifikasi bergantung pada hasil langkah segmentasi.

Baru-baru ini, SURF dipilih oleh [68] karena mereka menganggap bahwa SURF adalah metode yang mencapai hasil terbaik dalam waktu yang wajar. Tingkat akurasi yang dicapai sebesar 94,28% dengan 179 gambar dari dataset yang dibuat, dan waktu eksekusi yang diperoleh adalah 0,04 ms untuk satu keypoint SURF dan 5 ms per gambar. Dalam pendekatan ini, objek-objek yang terdeteksi pada area pemandangan yang serupa digabungkan menjadi satu objek, sehingga dua tanda yang saling bertumpukan dapat dianggap sebagai satu tanda tunggal yang dapat mempengaruhi penampilan yang serasi.

Metode pembelajaran berdasarkan fitur buatan tangan kurang akurat dibandingkan ConvNets; namun, kedua metode tersebut tidak dapat diskalakan dan tidak dapat mengklasifikasikan tanda-tanda wilayah lain atau kumpulan data baru. Karena skalabilitas atribut visual, mereka digunakan oleh [89], dikombinasikan dengan jaringan Bayesian yang dapat memperkirakan kemungkinan kelas masukan novel menggunakan observasi. Klasifikasi rate yang dicapai masing-masing kelas GTSRB adalah 97,01% untuk batas kecepatan, 97,09% untuk wajib, 96,31% untuk bahaya dan kelas lainnya sehingga rata-rata mencapai 98,04%.

kami merangkum metode klasifikasi berdasarkan fitur buatan tangan di Tabel 12. Namun, semua metode mencapai klasifikasi tingkat yang baik, dan tidak ada metode dengan klasifikasi tingkat tinggi dan proses positif palsu yang lebih sedikit secara real time, hal ini masih merupakan bidang penelitian terbuka.

### 3.2 Metode pembelajaran mendalam

Ciri-ciri kerajinan tangan tradisional memiliki kekuatan representasi yang terbatas dan sangat terkait dengan pengetahuan para ahli; Oleh karena itu, mereka tidak boleh melakukan diskriminasi

**Tabel 12**Metode klasifikasi rambu lalu lintas berdasarkan fitur buatan tangan

| Penulis                        | Kumpulan data yang digunakan | Fitur                                   | Kecepatan (%) |
|--------------------------------|------------------------------|-----------------------------------------|---------------|
| Abedin dkk. [63]               | 200 gambar                   | BERSELANCAR+JST                         | 97            |
| Aghdam dkk. [89]               | GTSRB                        | Atribut visual dengan Jaringan Bayesian | 98.04         |
| Ali dkk. [11]                  | 48 gambar                    | BERSELANCAR                             | 97,72         |
| Berkaya dkk. [76]              | GTSRB                        | GABOR                                   | 93,90         |
|                                |                              | LBP                                     | 93.36         |
|                                |                              | BABI                                    | 94.56         |
|                                |                              | HOG+LBP                                 | 95.24         |
|                                |                              | HOG+GABOR                               | 97.00         |
|                                |                              | Gabor+LBP                               | 95.17         |
|                                |                              | HOG+LBP+GABOR                           | 97.04         |
| Chen dkk. [69]                 | 200 gambar                   | BERSELANCAR+JST                         | 92.7          |
| Ellahyani dkk. [86]            | GTSRB                        | HOG di HSI+LSS dengan hutan acak        | 97.43         |
| Han dkk. [64] Dia dan Dai [72] | 1200 gambar                  | selancar+knm                            | 96            |
|                                | GTSRB                        | MS-CSLBP+DWT dengan SVM                 | 97,67         |
| Hoferlin dkk. [70]             | urutan 30 menit              | SIFT+SURF dengan MLP                    | 96.4          |
| Houben dkk. [43]               | GTSRB                        | Jendela geser dengan SVM                | 100           |
|                                |                              | Viola-Jones                             | 90,81         |
|                                |                              | BABI                                    | 70.33         |
| Hua dkk. [67]                  | 130 gambar                   | SIFT+kantong visual                     | 93            |
| Lasota dkk. [68]               | 179 gambar                   | BERSELANCAR                             | 94.28         |
| Li dkk. [74]                   | GTSRB                        | BABI                                    | 95.16         |
|                                |                              | LBP                                     | 95.38         |
| Liu dkk. [71]                  | GTSRB                        | Pengkodean kelompok yang jarang         | 97,83         |
| Malik dkk. [65]                | 172 gambar                   | MENYARING                               | 93,75         |
|                                |                              | BERSELANCAR                             | 81.25         |
|                                |                              | CEPAT                                   | 87.5          |
| Qu dkk. [62]                   | GTSRB                        | ACF dengan Adaboost                     | 95,97         |
|                                | STSD                         |                                         | 97,94         |
| Sathish dkk. [66]              | Video diambil di India       | MENYARING                               | 75 hingga 100 |
| Stallkamp dkk. [53]            | GTSRB                        | LDA+HOG1                                | 93.18         |
| Tang dkk. [73]                 | GTSRB                        | BABI                                    | 95,92         |
| Yakimov [61]                   | GTSRB                        | GHT dengan pra-pemrosesan               | 97.3          |
|                                |                              | GHT tanpa pemrosesan awal               | 89.3          |

kumpulan data yang sangat besar. Untuk mengatasi masalah ini dan mendorong kinerja pengenalan, diperlukan fitur yang mendalam. Pierre Sermanet dan Yann Le Cun [54] menggunakan Jaringan Konvolusional (ConvNets) untuk mempelajari fitur invarian rambu lalu lintas dengan cara yang diawasi menggunakan gambar input berwarna 32x32 dari kumpulan data GTSRB, dan akurasinya mencapai 98,97%, lebih tinggi dari kinerja manusia (98,81%). Selain itu, mereka meningkatkan kapasitas dan kedalaman jaringan mereka dengan mengabaikan informasi warna dan mereka mencetak rekor baru sebesar 99,17%.

Penulis memperoleh hasil terbaik tanpa informasi warna, sehingga mereka menduga bahwa saluran warna yang dinormalisasi mungkin lebih informatif daripada warna mentah, dan metode ini masih jauh dari penerapan waktu nyata.

Lapisan yang terhubung sepenuhnya dalam jaringan saraf konvolusional (CNN) dilatih melalui propagasi balik, dan sensitivitas propagasi balik serta pelatihan berlebih pada lapisan yang terhubung sepenuhnya dapat membuat kinerja generalisasi CNN menjadi kurang optimal. Biasanya, penulis menggunakan CNN sebagai fitur

**Tabel 13** Akurasi dan waktu pengolahan yang diperoleh Aghdam dkk. [58] dibandingkan dengan hasil [60]

| metode                      | Akurasi (%) | waktu CPU eksekusi (ms) | waktu GPU eksekusi (ms) |
|-----------------------------|-------------|-------------------------|-------------------------|
| 1 KonvNet [58]              | –           | 12.96                   | 1.06                    |
| 1 KonvNet ringkas [58] 1    | –           | 12.47                   | 1.03                    |
| KonvNet [60] 5 KonvNet [58] | –           | 14.47                   | 1.45                    |
|                             | 99.23       | 64.8                    | 5.30                    |
| 2 KonvNet Ringkas [58]      | 99.61       | 24.94                   | 2.06                    |
| 20 KonvNet [60]             | 99,65       | 289.4                   | 29.0                    |

ekstraktor dan pengklasifikasi, memang benar, dan mereka mendapatkan hasil yang mengesankan, dengan jaringan yang luas dan kompleks pada kumpulan data yang sangat besar. Di sisi lain, penulis di [57] mengusulkan pendekatan baru di mana CNN berfungsi sebagai ekstraktor fitur mendalam, yang berarti hanya delapan lapisan pertama yang dipertahankan dan menghilangkan lapisan yang terhubung sepenuhnya. Mesin pembelajaran ekstrim (ELM) kemudian digunakan sebagai pengklasifikasi karena generalisasi kinerjanya, dan menerima masukan dari CNN. Metode yang diusulkan memerlukan waktu pelatihan 5–6 jam tanpa implementasi GPU dan mencapai tingkat pengenalan 99,40% tanpa augmentasi data dan prapemrosesan seperti pada [56], namun metode ini tidak tahan terhadap kekaburan gerakan.

Qian dkk. [87] juga menggunakan CNN sebagai ekstraktor fitur dan multilayer perceptron (MLP) sebagai pengklasifikasi. Dibandingkan dengan ConvNet klasik, pada lapisan pooling maksimal penulis tidak menggunakan nilai maksimal, sebaliknya posisinya. Max pooling position (MPPs) terdiri dari mengkodekan setiap posisi nilai maksimal ke nilai biner 4 bit, kemudian menggabungkan semua nilai posisi maksimal untuk mendapatkan fitur MPPs. Akurasi yang dicapai dengan menggunakan MPP ditingkatkan menjadi 98,86% di GTSRB.

Xie dkk. [88] mengamati bahwa 80% tanda yang salah klasifikasi memiliki warna, bentuk, dan piktoqram yang sama. Untuk mengatasi masalah ini, mereka mengusulkan CNN berjenjang dua tahap. CNN tahap pertama dilatih pada label kelas, sedangkan tahap kedua dilatih pada kelas super secara terpisah sesuai bentuk dan piktoqramnya. Keakuratan metode yang diusulkan adalah 97,94% pada GTSRB, dan mereka mengurangi jumlah kesalahan klasifikasi dengan CNN berjenjang dari 430 menjadi 202. Waktu pelaksanaan tidak disebutkan.

Arsitektur ConvNet baru yang diusulkan oleh [58] dapat mengurangi jumlah parameter 27, 22 dan 3% dibandingkan dengan ConvNets yang digunakan oleh [54,59,60], masing-masing; kemudian mereka mengusulkan ConvNet kompak yang mengurangi jumlah parameter 52% dibandingkan dengan ConvNet yang diusulkan. Untuk meningkatkan akurasi klasifikasi, mereka juga mengusulkan metode baru untuk membuat ConvNets yang optimal dengan memilih jumlah ConvNets yang optimal dengan akurasi setinggi mungkin dan dengan jumlah operasi aritmatika yang lebih sedikit yaitu 88 dan 73% dibandingkan dengan [59,60], masing-masing. Akurasi yang dicapai metode yang mereka usulkan pada dataset GTSRB adalah 99,23% dengan

2 ConvNets (compact ConvNet) dan 99,61% dengan hanya 5 ConvNets yang sangat mengurangi waktu eksekusi seperti yang diilustrasikan pada Tabel 13. Di samping itu, [54] memiliki akurasi 99,46% dengan ansambel 25 ConvNet, dan [60] mencapai akurasi 99,65% menggunakan 20 ConvNets. Untuk menguji skalabilitas dan kinerja lintas kumpulan data dari newConvNet yang diusulkan oleh [58], mereka menggunakan ConvNet yang sudah dilatih di GTSRB untuk mengidentifikasi rambu lalu lintas di dataset BTSC, dan akurasi yang diperoleh adalah 92,12%.

Arsitektur sederhana jaringan saraf dalam digunakan oleh [80] untuk mengenali rambu lalu lintas melingkar, dan mencapai tingkat pengenalan sebesar 97,5% di GTSRB. Dua arsitektur CNN lainnya diusulkan oleh [81], dan arsitektur skala tunggal terdiri dari dua tahap lapisan konvolusional dan dua lapisan lokal yang terhubung penuh diikuti oleh pengklasifikasi softmax. Dalam arsitektur multiskala, keluaran dari lapisan konvolusional pertama dianggap sebagai masukan untuk lapisan konvolusional kedua dan lapisan konvolusional pertama yang terhubung penuh. Kedua arsitektur tersebut dievaluasi berdasarkan kumpulan data GTSRB dan kumpulan data barunya DITS (Kumpulan Data Rambu Lalu Lintas Italia). Tingkat akurasi yang dicapai pada GTSRB adalah 97,2% untuk arsitektur skala tunggal dan 98,2% untuk arsitektur multiskala, dan untuk dataset DITS tingkat akurasi yang dicapai adalah 93,1% untuk skala tunggal dan 95,0% untuk multiskala.

Dan Cirean dkk. [55] menggunakan implementasi GPU dari jaringan saraf konvolusional dan mereka menerapkan pra-pemrosesan pada gambar masukan dengan mengubah ukuran semua gambar menjadi 48x48 piksel dan mereka menguji tiga jenis normalisasi untuk mengatasi variasi kontras tinggi dan mereka memperoleh tingkat pengenalan sebesar 99,15% dengan menggunakan komite multilayer perceptrons (MLPs) yang dilatih dengan deskriptor fitur HOG dan CNN yang dilatih tentang intensitas piksel mentah untuk meningkatkan kinerja pengenalan. Setelah mereka memenangkan tahap akhir tolak ukur pengenalan rambu lalu lintas Jerman dengan tingkat pengenalan 99,46% di [56], mereka menggunakan jaringan saraf dalam multi-kolom (MCDNN) dengan merata-ratakan aktivasi keluaran beberapa kolom DNN.

Aghdam dkk. [78] mengusulkan arsitektur baru CNN yang mencetak rekor akurasi klasifikasi baru 99,51%. Arsitektur yang diusulkan mengurangi 85% jumlah parameter dan 88% perkalian dibandingkan dengan jaringan pemenang yang dilaporkan dalam Tolak Ukur Rambu Lalu Lintas Jerman



**Tabel 14**Metode klasifikasi pembelajaran mendalam

| Penulis            | Kumpulan data yang digunakan | metode                   | Kecepatan (%) |
|--------------------|------------------------------|--------------------------|---------------|
| Aghdam dkk. [58]   | GTSRB                        | KonvNet Baru             | 99.23         |
|                    |                              | KonvNet Ringkas          | 99.61         |
|                    |                              | ConvNet dilatih di GTSRB | 92.12         |
| Aghdam dkk. [78]   | GTSRB                        | New CNN                  | 99,51         |
| Aghdam dkk. [77]   | GTSRB                        | CNN tunggal              | 99,55         |
|                    |                              | 3 CNN                    | 99,70         |
|                    |                              | MCDNN                    | 99,46         |
| Cirean dkk. [56]   | GTSRB                        | MLP+HOG+CNN              | 99.15         |
| Eickel [80]        | GTSRB                        | DNN baru                 | 97,5          |
| Jin [60]           | GTSRB                        | 20 KonvNet               | 99,65         |
| Qian dkk. [87]     | GTSRB                        | CNN+MLP                  | 98,86         |
| Qu dkk. [62]       | GTSRB                        | ACF dengan Adaboost      | 95,97         |
|                    |                              | STSD                     | 97,94         |
|                    |                              | Jaringan                 | 98,97         |
| Sermanet dkk. [54] | GTSRB                        | Kinerja manusia          | 98.8          |
|                    |                              | Konvnet tanpa warna      | 99.17         |
|                    |                              | CNN berjenjang           | 97,94         |
| Yusuf [81]         | GTSRB                        | CNN skala tunggal        | 97.2          |
| Zeng dkk. [57]     | GTSRB                        | CNN+ELM                  | 99.40         |

**Tabel 15**Tersedia kumpulan data klasifikasi

| Himpunan data             | Kelas | Gambar-gambar | Properti                                                     |
|---------------------------|-------|---------------|--------------------------------------------------------------|
| GTSRB [53]                | 43    | 50000         | Ukuran gambar: 15×15 hingga 222×193 piksel<br>Negara: Jerman |
| BTSC [49]                 | 62    | 6000          | Ukuran gambar: NA Negara: Belgia Ukuran                      |
| MASTIF yang direvisi [51] | 30    | 6000          | gambar: 64×64 piksel Negara: Kroasia Negara:                 |
| DIT [81]                  | 58    | 9254          | Italia                                                       |

kompetisi [56]. Pengurangan ini dicapai dengan menggunakan Leaky Rectified Linear Units (ReLU) [79] sebagai fungsi aktivasi yang hanya menggunakan satu perbandingan dan satu perkalian untuk menghitung keluaran.

Rekor baru klasifikasi rambu lalu lintas kembali diraih oleh Aghdam dkk. [77], dan mereka mengusulkan varian baru dari CNN sebelumnya yang diusulkan di [78]. Penulis mengganti gambar berwarna dengan skala abu-abu tersebut, dan mereka menghapus lapisan transformasi linier. Dan untuk meningkatkan fleksibilitas, lapisan yang terhubung sepenuhnya ditambahkan ke jaringan dan mereka mengurangi ukuran kernel pertama dan tengah serta gambar masukan diubah ukurannya menjadi 44×44 piksel untuk mengurangi waktu pemrosesan. Akurasi terbaik baru yang dicapai adalah 99,55% dengan CNN tunggal dan 99,70% dengan ensemble 3 CNN. CNN baru bersifat real time dengan waktu pemrosesan 0,7 ms per gambar.

Di meja 14, kami merangkum metode pembelajaran mendalam.

### 3.3 Kumpulan data klasifikasi yang tersedia untuk umum

- Tolok Ukur Pengenalan Rambu Lalu Lintas Jerman—kumpulan data GTSRB [53]: Klasifikasi rambu lalu lintas GTSRB

dataset terdiri dari 43 kelas yang berisi lebih dari 50.000 gambar. Jumlah rambu lalu lintas pada setiap kelas minimal 9 rambu lalu lintas dengan ukuran bervariasi antara 15×15 hingga 222×193 piksel. Untuk memungkinkan pencari yang tidak memiliki latar belakang pemrosesan gambar untuk berpartisipasi dalam kompetisi, disediakan tiga fitur yang telah dihitung sebelumnya: tiga konfigurasi fitur HOG (HOG1, HOG2, HOG3), fitur mirip Haar, dan histogram rona (Tabel 15).

- Klasifikasi Rambu Lalu Lintas Belgia—dataset BTSC [49]: Dataset BTSC hanyalah ekstraksi wilayah yang diminati yang berisi rambu lalu lintas dalam dataset BTSD, dan terdiri dari lebih dari 4000 gambar pelatihan yang diklasifikasikan dalam 62 kelas dan lebih dari 2000 gambar pengujian.
- Kumpulan data MASTIF yang direvisi: MASTIF yang direvisi [51]: Ini adalah bagian dari kumpulan data MASTIF yang diperoleh dengan mengekstraksi contoh rambu lalu lintas dari wilayah yang diminati dalam kumpulan data MASTIF. Ini terdiri dari 4028 gambar pelatihan dan 1644 gambar pengujian. Gambar didistribusikan pada 30 kelas.
- Data DITS (Kumpulan Data Rambu Lalu Lintas Italia) [81]: Subset klasifikasi terdiri dari 8048 gambar untuk

pelatihan dan 1206 untuk pengujian. Ini berisi total 58 kelas tanda dengan ukuran berbeda.

#### 4 Arah penelitian masa depan

Masalah dengan teknologi canggih saat ini adalah kurangnya kebenaran dasar dan kumpulan data universal yang berisi tanda-tanda dari berbagai wilayah (termasuk wilayah yang tidak mematuhi Konvensi Wina tentang rambu dan sinyal jalan) dan ditangkap dalam kondisi berbeda. Karena kumpulan data yang tersedia sudah mencapai titik jenuh, kami memandang diperlukan kumpulan data baru yang universal dan lebih kompleks. Masalah lain dari dataset yang tersedia saat ini adalah ketidakseimbangan distribusi sampel pada kelas rambu lalu lintas yang dapat berdampak negatif pada kinerja klasifikasi; untuk mengatasi masalah ini, diperlukan dataset baru yang seimbang.

Kami menyarankan untuk penelitian selanjutnya menggunakan gambar resolusi tinggi dalam dataset deteksi, jika kita menganggap bahwa kecepatan mobil adalah 100km/jam dan ada tanda menjauh dari mobil sekitar 27m; oleh karena itu, tanda ini akan dilewati dalam 1s. Oleh karena itu, gambar kumpulan data harus beresolusi tinggi agar dapat mendeteksi tanda-tanda jauh dengan jelas. Peneliti dapat lebih fokus pada modul pelacakan untuk mengikuti tanda-tanda karena jika sistem menggunakan kamera dengan 30 frame pengambilan gambar per detik, sistem harus dapat mendeteksi dan mengenali semua tanda dari 30 frame dalam 1 detik; Namun, dengan modul pelacakan, nyanyian yang terdeteksi dan dilacak tidak akan diklasifikasikan ulang dalam setiap frame yang ditangkap tetapi hanya satu kali hingga munculnya tanda-tanda baru.

Sistem pengenalan rambu lalu lintas terdiri dari tahapan deteksi dan klasifikasi. Karena kinerja klasifikasi bergantung pada hasil deteksi, hal ini membuat penentuan solusi terbaik menjadi proses yang membosankan. Seperti yang ditunjukkan dalam pendahuluan, inti masalahnya bukanlah mendeteksi rambu lalu lintas dengan daya ingat yang tinggi; namun, mendapatkan presisi tinggi lebih penting. Kami menyarankan untuk memfokuskan penelitian pada bagaimana mengurangi alarm palsu dalam deteksi rambu lalu lintas.

Untuk meningkatkan akurasi tahap klasifikasi, peneliti harus lebih fokus pada pencarian dan analisis fitur yang lebih diskriminan yang dapat mewakili kelas rambu lalu lintas yang berbeda dengan lebih baik. Saat ini, fitur dalam lebih diskriminatif dibandingkan fitur buatan tangan; namun demikian, belum ada penelitian mengenai metode pembelajaran, yang membuktikan skalabilitasnya untuk kumpulan data baru yang dapat membuka jalan bagi penelitian di masa depan.

#### 5. Kesimpulan

Dalam makalah ini, kami telah menyajikan gambaran umum tentang beberapa metode deteksi dan klasifikasi rambu lalu lintas yang terbaru dan efisien. Metode deteksi dibagi menjadi tiga kategori: color based yang diklasifikasikan berdasarkan ruang warna, shape based, dan learning based yang mencakup metode deep learning. Metode deteksi terkini mencapai tingkat deteksi yang bervariasi

dari 90 hingga 100% dengan kumpulan data yang tersedia dijelaskan secara singkat di makalah. Meskipun demikian, sulit untuk memutuskan metode mana yang terbaik.

Untuk memperoleh tingkat klasifikasi yang tinggi, perlu mengadopsi fitur-fitur yang diskriminatif dan pengklasifikasi yang kuat. Hasil yang dapat diterima dicapai dengan metode pembelajaran menggunakan fitur buatan tangan, dan terlebih lagi, kinerja metode klasifikasi ditingkatkan dengan metode pembelajaran mendalam seperti CNN dan metode tersebut mencapai tingkat akurasi yang tinggi >99%. Karena kumpulan data yang tersedia sudah mencapai titik jenuh, kumpulan data universal baru yang lebih kompleks sangat diperlukan.

Namun, metode deteksi dan klasifikasi mencapai tingkat akurasi yang tinggi, dan masih jauh dari penerapan ADAS real-time di mana tanda harus dideteksi dan diklasifikasikan secara real-time.

Pertanyaan yang diajukan adalah: Dapatkah metode deteksi dan klasifikasi rambu lalu lintas terkini membuktikan kinerja yang sama dalam penerapan di dunia nyata atau dengan kumpulan data kebenaran dasar lainnya? Bisakah mereka membuktikan dengan perangkat ponsel pintar eksekusi real-time yang sama seperti yang diperoleh di lingkungan cpu dan GPU? Terakhir, sistem pengenalan rambu lalu lintas universal masih merupakan bidang penelitian yang terbuka.

#### Referensi

1. Gudigar A, Chokkadi S, Raghavendra U (2016) Tinjauan tentang deteksi otomatis dan pengenalan rambu lalu lintas. *Aplikasi Alat Multimed* 75(1):333–364
2. Fu MY, Huang YS (2010) Survei pengenalan rambu lalu lintas. Dalam: *Konferensi internasional tentang analisis wavelet dan pengenalan pola (ICWAPR)*, 2010, IEEE, hal 119–124
3. Wali SB, Hannan MA, Hussain A, Samad SA (2015) Survei komparatif deteksi dan pengenalan rambu lalu lintas: tinjauan. *Przegld Elektrotechnikzny*, ISSN: 0033-2097
4. Escalera S, Bar X, Pujol O, Vitri J, Radeva P (2011) Latar belakang deteksi dan pengenalan rambu lalu lintas. Dalam: *Sistem pengenalan rambu lalu lintas*. Springer, London, hal 5–13
5. De La Escalera A, Moreno LE, Salichs MA, Armingol JM (1997) Deteksi dan klasifikasi rambu lalu lintas jalan. *IEEE Trans Indus Elektron* 44(6):848–859
6. Benallal M, Meunier J (2003) Segmentasi warna rambu jalan secara real-time. Dalam: *Konferensi Kanada tentang teknik elektro dan komputer*, vol 3, 2003, IEEE/CECE 2003, IEEE, hal 1823–1826
7. Ruta A, Li Y, Liu X (2010) Pengenalan rambu lalu lintas secara real-time dari video berdasarkan fitur diskriminatif kelas tertentu. *Pengenalan Pola* 43(1):416–430
8. RutaA, Porikli F, Watanabe S, Li Y (2011) Deteksi dan pengenalan rambu lalu lintas kamera di dalam kendaraan. *Aplikasi Mach Vis* 22(2):359–375
9. LimKH, AngLM, SengKP (2009) Teknik hybrid baru untuk pengenalan rambu lalu lintas. Dalam: *Simposium internasional tentang pemrosesan sinyal cerdas dan sistem komunikasi*, 2008. *ISPACS* 2008, IEEE, hal 1–4
10. Itti L, Koch C, Niebur E (1998) Sebuah model perhatian visual berbasis arti-penting untuk analisis adegan cepat. *IEEE Pola Trans Anal Mach Intell* 20(11):1254–1259
11. Behloul A, Saadna Y (2014) Pengenalan Rambu Lalu Lintas yang Cepat dan Kuat. *Int J Innov Aplikasi Stud* 5(2):139
12. Yakimov P (2015) Deteksi rambu lalu lintas menggunakan tracking dengan prediksi. Dalam: *Konferensi internasional tentang E-bisnis dan telekomunikasi Colmar*, Perancis, Springer, hal 454–467

13. Yakimov PY (2015) Memproses awal gambar digital untuk mendeteksi rambu jalan dengan cepat dan andal. *Anal Gambar Pengenalan Pola* 25(4):729–732
14. Wang G, Ren G, Jiang L, Quan T (2014) Metode deteksi rambu lalu lintas berbasis lubang untuk rambu lalu lintas dengan pelek merah. *Vis Komputasi* 30(5):539–551
15. Mogelmoose A, Trivedi MM, Moeslund TB (2012) Deteksi dan analisis rambu lalu lintas berbasis visi untuk sistem bantuan pengemudi cerdas: Perspektif dan survei. *Sistem Trans Intell IEEE* 13(4):1484–1497
16. Maldonado-Bascon S, Lafuente-Arroyo S, Gil-Jimenez P, Gomez-Moreno H, Lopez-Ferreras F (2007) Deteksi dan pengenalan rambu jalan berdasarkan mesin vektor pendukung. *Sistem Trans Intell Transp IEEE* 8(2):264–278
17. Fleyeh H (2006) Bayangan dan sorot algoritma segmentasi warna invarian untuk rambu lalu lintas. Dalam: *Konferensi IEEE tentang sibermetika dan sistem cerdas*, 2006, IEEE, hal 1–7
18. Vitabile S, Pollaccia G, Pilato G, Sorbello F (2001) Pengenalan rambu jalan menggunakan teknik agregasi piksel dinamis dalam ruang warna HSV. Dalam: *Prosiding konferensi internasional ke-11 tentang analisis dan pemrosesan gambar*, 2001, IEEE, hal 572–577
19. De la Escalera A, Armingol JM, Mata M (2003) Pengenalan dan analisis rambu lalu lintas untuk kendaraan cerdas. *Gambar Vis Comput* 21(3):247–258
20. Fang CY, Fuh CS, Yen PS, Cherng S, Chen SW (2004) Sistem pengenalan rambu jalan otomatis berdasarkan model komputasi pemrosesan pengenalan manusia. *Komputasi Gambar Vis Underst* 96(2):237–268
21. Miura J, Kanda T, Nakatani S, Shirai Y (2002) Sistem visi aktif untuk pengenalan rambu lalu lintas online. *TRANSAKSI IEICE pada Sistem Inf* 85(11):1784–1792
22. Broggi A, Cerri P, Medici P, Porta PP, Ghisio G (2007) Pengenalan rambu jalan waktu nyata. Dalam: *Simposium kendaraan cerdas IEEE*, 2007, IEEE, hal 981–986
23. Gmez-Moreno H, Maldonado-Bascn S, Gil-Jimnez P, Lafuente-Arroyo S (2010) Evaluasi tujuan algoritma segmentasi untuk pengenalan rambu lalu lintas. *Sistem Trans Intell IEEE* 11(4):917–930
24. Liu C, Chang F, Chen Z, Liu D (2016) Pengenalan rambu lalu lintas cepat melalui ekstraksi wilayah kontras tinggi dan representasi renggang yang diperluas. *Sistem Trans Intell IEEE* 17(1):79–92
25. Hechri A, Hmida R, Mtibaa A (2015) Pengenalan jalur jalan dan rambu lalu lintas yang kokoh untuk sistem bantuan pengemudi. *Int J Komputasi Sci Eng* 10(1–2):202–209
26. Garcia-Garrido MA, Sotelo MA, Martin-Gorostiza E (2006) Deteksi dan pengenalan rambu lalu lintas dengan cepat dalam kondisi pencahayaan yang berubah. Dalam: *Konferensi sistem transportasi cerdas IEEE*, 2006 ITSC'06, IEEE, hal. 811–816
27. Barnes N, Zelinsky A (2004) Simetri radial waktu nyata untuk deteksi tanda kecepatan. Dalam: *Simposium kendaraan cerdas IEEE*, 2004, IEEE, hal 566–571
28. Loy G, Barnes N (2004) Deteksi rambu jalan berbasis bentuk cepat untuk sistem bantuan pengemudi. Dalam: *Prosiding konferensi internasional IEEE/RSJ 2004 tentang robot dan sistem cerdas*, 2004 (IROS 2004) Vol 1, IEEE, hal 70–75
29. Soheilian B, Arlicot A, Paparoditis N (2010) Ekstraksi panneaux de signalisation rutin dans des images couleurs. Dalam: *Reconnaissance des Formes et Intelligence Artificielle*, hal 1–8
30. Zhang SC, Liu ZQ (2005) Detektor elips real-time yang kuat. *Pengenalan Pola* 38(2):273–287
31. Larsson F, Felsberg M (2011) Menggunakan deskriptor Fourier dan model spasial untuk pengenalan rambu lalu lintas. Dalam: *Konferensi Skandinavia tentang analisis gambar*, Springer, Berlin, Heidelberg, hal 238–249
32. Qin F, Fang B, Zhao H (2010) Segmentasi dan pengenalan rambu lalu lintas dalam gambar pemandangan. Dalam: *Konferensi Tiongkok tentang pengenalan pola (CCPR)*, hal 1–5
33. Viola P, Jones M (2001) Deteksi objek cepat menggunakan rangkaian fitur sederhana yang ditingkatkan. Dalam: *Prosiding konferensi masyarakat komputer IEEE 2001 tentang visi komputer dan pengenalan pola*, CVPR 2001, vol 1, IEEE, p 1
34. Brkic K, Pinz A, Šegvic S (2009) Deteksi rambu lalu lintas sebagai komponen sistem inventaris infrastruktur lalu lintas otomatis. *Stainz, Austria*
35. Brki K, Šegvi S, Kalafati Z, Sikiri I, Pinz A (2010) Pemodelan generatif lintasan rambu lalu lintas spatio-temporal. Dalam: *Konferensi masyarakat komputer IEEE tentang lokakarya visi komputer dan pengenalan pola (CVPRW)*, 2010, IEEE, hal 25–31
36. Brkic K (2010) Gambaran umum metode deteksi rambu lalu lintas. *Jurusan Elektronika, Mikroelektronika, Komputer dan Sistem Cerdas Fakultas Teknik Elektro dan Komputasi Unska*, 3, 10000
37. Bar X, Escalera S, Vitri J, Pujol O, Radeva P (2009) Pengenalan rambu lalu lintas menggunakan deteksi adaboost evolusioner dan klasifikasi hutan-ECOC. *Sistem Trans Intell IEEE* 10(1):113–126
38. Priscariu VA, Timofte R, Zimmermann K, Reid I, Van Gool L (2010) Mengintegrasikan deteksi objek dengan pelacakan 3d menuju sistem bantuan pengemudi yang lebih baik. Dalam: *Konferensi Internasional ke-20 tentang pengenalan pola (ICPR)*, 2010, IEEE, hal 3344–3347
39. Fang CY, Chen SW, Fuh CS (2003) Deteksi dan pelacakan rambu jalan. *Teknologi Trans Kendaraan IEEE* 52(5):1329–1341
40. Zaklouta F, Stanculescu B (2011) Pengenalan rambu lalu lintas peringatan menggunakan pohon Kd berbasis HOG. Dalam: *Simposium kendaraan cerdas IEEE (IV)*, 2011. IEEE, hal 1019–1024
41. Dalal N, Triggs B (2005) Histogram gradien berorientasi untuk deteksi manusia. Dalam: *Konferensi masyarakat komputer IEEE tentang visi komputer dan pengenalan pola*, CVPR 2005, vol 1, IEEE hal 886–893
42. Wang G, Ren G, Wu Z, Zhao Y, Jiang L (2013) Metode deteksi rambu lalu lintas yang kuat dan kasar. Dalam: *Konferensi gabungan internasional tentang jaringan saraf (IJCNN)* tahun 2013, IEEE, hal 1–5
43. Houben S, Stallkamp J, Salmen J, Schlipsing M, Igel C (2013) Deteksi rambu lalu lintas dalam gambar dunia nyata: Tolok Ukur Deteksi Rambu Lalu Lintas Jerman. Dalam: *Konferensi gabungan internasional tentang jaringan saraf (IJCNN)* tahun 2013, IEEE, hal 1–8
44. Houben S (2011) Skema pemungutan suara target tunggal untuk deteksi rambu lalu lintas. Dalam: *Simposium kendaraan cerdas IEEE (IV)*, 2011, IEEE, hal 124–129
45. Mathias M, Timofte R, Benenson R, Van Gool L (2013) Pengenalan rambu lalu lintas Seberapa jauh kita dari solusi?. Dalam: *Konferensi gabungan internasional tentang jaringan saraf (IJCNN)* tahun 2013, IEEE, hal 1–8
46. Wu Y, Liu Y, Li J, Liu H, Hu X (2013) Deteksi rambu lalu lintas berdasarkan jaringan saraf konvolusional. Dalam: *Konferensi gabungan internasional tentang jaringan saraf (IJCNN)* tahun 2013, hal 1–7, IEEE
47. Liu C, Chang F, Chen Z, Li S (2013) Deteksi dan klasifikasi rambu lalu lintas cepat menggunakan pohon kategori yang ditetapkan pertama. *J Sistem Inf Komputasi* 9(18):7461–7468
48. Liu C, Chang F, Chen Z (2014) Deteksi rambu lalu lintas multikelas yang cepat dalam gambar resolusi tinggi. *Sistem Trans Intelijen IEEE* 15(6):2394–2403
49. Timofte R, Zimmermann K, Van Gool L (2009) Deteksi rambu lalu lintas multi-tampilan, pengenalan, dan lokalisasi 3d. Dalam: *Lokakarya penerapan visi komputer (WACV)*, 2009, IEEE, hal 1–8
50. Mogelmoose A, Trivedi MM, Moeslund TB (2012) Belajar mendeteksi rambu lalu lintas: evaluasi komparatif kumpulan data sintetik dan dunia nyata. Dalam: *Konferensi Internasional ke-21 tentang pengenalan pola (ICPR)*, 2012, IEEE, hal 3452–3455
51. Šegvic S, Brki K, Kalafati Z, Stanisavljevi V, evrovi M, Budimir D, Dadi I (2010) Visi komputer membantu inventarisasi geoinformasi untuk infrastruktur lalu lintas. Dalam: *Konferensi IEEE Internasional ke-13 tentang sistem transportasi cerdas (ITSC)*, 2010, IEEE, hal 66–73

52. Zaklouta F, Stanculescu, B., Hamdoun, O. (2011) Klasifikasi rambu lalu lintas menggunakan pohon kd dan hutan acak. Dalam: Konferensi gabungan internasional tentang jaringan saraf (IJCNN) tahun 2011, hal 2151–2155, IEEE
53. Stallkamp J, Schlipsing M, Salmen J, Igel C (2012) Manusia vs. komputer: membandingkan algoritma pembelajaran mesin untuk pengenalan rambu lalu lintas. *Jaringan saraf* 32:323–332
54. Sermanet P, LeCun Y (2011) Pengenalan rambu lalu lintas dengan jaringan konvolusional multiskala. Dalam konferensi gabungan internasional tentang jaringan saraf (IJCNN) tahun 2011, IEEE, hal 2809–2813
55. Cirean D, Meier U, Masci J, Schmidhuber J (2011) Komite jaringan saraf untuk klasifikasi rambu lalu lintas. Dalam: Konferensi gabungan internasional tentang jaringan saraf (IJCNN) tahun 2011, IEEE, hal 1918–1921
56. Cirean D, Meier U, Masci J, Schmidhuber J (2012) Jaringan saraf dalam multi-kolom untuk klasifikasi rambu lalu lintas. *Jaringan Syaraf* 32:333–338
57. Zeng Y, Xu X, Fang Y, Zhao K (2015) Pengenalan rambu lalu lintas menggunakan pengklasifikasi pembelajaran ekstrim dengan fitur konvolusional yang mendalam. Di: Konferensi internasional tahun 2015 tentang ilmu intelijen dan rekayasa data besar (ISIDE 2015), Suzhou, Tiongkok
58. Aghdam HH, Heravi EJ, Puig D (2017) Jaringan saraf konvolusional yang praktis dan sangat optimal untuk mengklasifikasikan rambu lalu lintas secara real-time. *Int J Komputasi Vis* 122(2):246–269
59. Ciregan D, Meier U, Schmidhuber J (2012) Jaringan saraf dalam multi-kolom untuk klasifikasi gambar. Dalam konferensi IEEE tentang visi komputer dan pengenalan pola (CVPR), 2012, IEEE, hal 3642–3649
60. Jin J, Fu K, Zhang C (2014) Pengenalan rambu lalu lintas dengan jaringan saraf konvolusional terlatih yang kehilangan engsel. *Sistem Trans Intell IEEE* 15(5):1991–2000
61. Yakimov PY (2016) Pengenalan rambu jalan secara real-time menggunakan GPU seluler. Dalam: prosiding lokakarya CEUR, vol 1638, hlm 477–483
62. Qu Y, Yang S, Wu W, Lin L (2016) Pengenalan rambu lalu lintas hierarki. Dalam: Konferensi Lingkar Pasifik tentang Multimedia, Springer, hal 200–209
63. Abedin MZ, Dhar P, Deb K (2016) Pengenalan Rambu Lalu Lintas menggunakan SURF: mempercepat deskriptor fitur yang kuat dan pengklasifikasi jaringan saraf tiruan. Dalam: Konferensi Internasional ke-9 tentang teknik elektro dan komputer (ICECE), 2016, IEEE, hal 198–201
64. Han Y, Virupakshappa K, Oruklu E (2015) Pengenalan rambu lalu lintas yang kuat dengan metode ekstraksi fitur dan klasifikasi k-NN. Dalam: Konferensi internasional IEEE tentang teknologi elektro/informasi (EIT), 2015, IEEE, hal 484–488
65. Malik Z, Siddiqi I (2014) Deteksi dan pengenalan rambu lalu lintas dari gambar pemandangan jalan. Dalam: Konferensi Internasional ke-12 tentang batas-batas teknologi informasi (FIT), 2014, IEEE, hal 330–335
66. Sathish P, Bharathi D (2016) Deteksi dan pengenalan rambu jalan otomatis berdasarkan algoritma pencocokan fitur SIFT. Dalam: Prosiding konferensi internasional tentang sistem komputasi lunak. Springer India, hal 421–431
67. Hua X, Zhua X, Lia D, Li H (2010) Pengenalan rambu lalu lintas menggunakan transformasi fitur Scale invariant dan SVM. Dalam: Simposium gabungan khusus komisi teknis IV ISPRS dan AutoCarto bersamaan dengan konferensi khusus musim gugur ASPRS/CaGIS November, hal 15–19
68. Lasota M, Skoczylas M (2016) Pengenalan beberapa rambu lalu lintas menggunakan detektor fitur titik kunci. Dalam: Konferensi dan eksposisi internasional tentang teknik kelistrikan dan tenaga (EPE), 2016, IEEE, hal 535–540
69. Chen L, Li Q, Li M, Mao Q (2011) Deteksi dan pengenalan rambu lalu lintas untuk kendaraan cerdas. Dalam: Simposium kendaraan cerdas IEEE (IV), 2011, IEEE, hal 908–913
70. Hoferlin B, Zimmermann K (2009) Menuju pengenalan rambu lalu lintas yang andal. Dalam: Simposium kendaraan cerdas IEEE, 2009, IEEE, hal 324–329
71. Liu H, Liu Y, Sun F (2014) Pengenalan rambu lalu lintas menggunakan pengkodean renggang kelompok. *Inf Sains* 266:75–89
72. He X, Dai B (2016) Pendekatan klasifikasi rambu lalu lintas baru berdasarkan ekstraksi fitur lokal dan global. Dalam: Konferensi internasional tentang komunikasi dan manajemen informasi (ICICM), IEEE, hal 121–125
73. Tang S, Huang LL (2013) Pengenalan rambu lalu lintas menggunakan fitur pelengkap. Dalam: Konferensi Asia IAPR ke-2 tentang pengenalan pola (ACPR), 2013, IEEE, hal 210–214
74. Li C, Yang C (2016) Penelitian pengenalan rambu lalu lintas berbasis deep learning. Dalam: Simposium Internasional ke-16 tentang teknologi komunikasi dan informasi (ISCIT), 2016, IEEE, hal 156–161
75. Akinlar C, Topal C (2013) EDCircles: detektor lingkaran real-time dengan kontrol deteksi palsu. *Pengenalan Pola* 46(3):725–740
76. Berkaya SK, Gunduz H, Ozsen O, Akinlar C, Gunal S (2016) Tentang deteksi dan pengenalan rambu lalu lintas melingkar. *Aplikasi Sistem Pakar* 48:67–75
77. Aghdam HH, Heravi EJ, Puig D (2016) Pendekatan praktis untuk deteksi dan klasifikasi rambu lalu lintas menggunakan Convolutional Neural Networks. *Sistem Auton Robot* 84:97–112
78. Aghdam HH, Heravi EJ, Puig D (2016) Mengenal rambu lalu lintas menggunakan jaringan saraf dalam yang praktis. Dalam: Robot 2015: konferensi robotika Iberia ke-2, Springer, hal 399–410
79. Maas AL, Hannun AY, Ng AY (2013) Penyearah nonlinier meningkatkan model akustik jaringan saraf. Dalam: Prosiding ICML, vol 30, No 1
80. Eickeler S, Valdenegro M, Werner T, Kieninger M (2016) Algoritma visi komputer masa depan untuk sistem pengenalan rambu lalu lintas. Dalam: Sistem mikro tingkat lanjut untuk aplikasi otomotif 2015, Springer, hlm 69–77
81. Youssef A, Albani D, Nardi D, Bloisi DD (2016) Pengenalan rambu lalu lintas cepat menggunakan segmentasi warna dan jaringan konvolusional yang dalam. Dalam: Konferensi internasional tentang konsep lanjutan untuk sistem penglihatan cerdas, Springer, hal 205–216
82. Huang Z, Yu Y, Gu J, Liu H (2016) Metode yang efisien untuk pengenalan rambu lalu lintas berdasarkan mesin pembelajaran ekstrim. *IEEE Trans Cybern* 47(4):920–933
83. Zang D, Zhang J, Zhang D, Bao M, Cheng J, Tang K (2016) Deteksi rambu lalu lintas berdasarkan jaringan saraf konvolusional berjenjang. Dalam: Konferensi internasional IEEE/ACIS ke-17 tentang rekayasa perangkat lunak, kecerdasan buatan, jaringan dan komputasi paralel/terdistribusi (SNPD), 2016, IEEE, hal 201–206
84. Salti S, Petrelli A, Tombari F, Fioraio N, Di Stefano L (2015) Deteksi rambu lalu lintas melalui ekstraksi wilayah kepentingan. *Pengenalan Pola* 48(4):1039–1049
85. Chen T, Lu S (2016) Deteksi rambu lalu lintas yang akurat dan efisien menggunakan adaboost diskriminatif dan regresi vektor pendukung. *Teknologi Trans Kendaraan IEEE* 65(6):4006–4015
86. Ellahyani A, El Ansari M, El Jaafari I (2016) Deteksi dan pengenalan rambu lalu lintas berdasarkan hutan acak. *Aplikasi Komputasi Lunak* 46:805–815
87. Qian R, Yue Y, Coenen F, Zhang B (2016) Pengenalan rambu lalu lintas dengan jaringan saraf konvolusional berdasarkan posisi pengumpulan maksimal. Dalam: Konferensi Internasional ke-12 tentang komputasi alami, sistem fuzzy, dan penemuan pengetahuan (ICNC-FSKD), 2016, IEEE, hal 578–582
88. Xie K, Ge S, Ye Q, Luo Z (2016) Pengenalan rambu lalu lintas berdasarkan jaringan saraf konvolusional bertingkat penyempurnaan atribut. Dalam: Konferensi Lingkar Pasifik tentang Multimedia, Springer, hal 201–210
89. Aghdam HH, Heravi EJ, Puig D (2015) Pengenalan rambu lalu lintas menggunakan atribut visual dan jaringan Bayesian. Dalam: Konferensi gabungan internasional tentang visi komputer, pencitraan dan grafik komputer, Springer, hal 295–315